1. 当代 Agent 记忆管理系统入门介绍

> Agent 记忆系统公开课（上集）· Part 1 · 背景认知

§1a 开场：你每天用的 AI 工具之所以强，是因为它们都有记忆系统

上下文即一切

大多数初级 Agent 工程师在第一次接触 LangChain / LlamaIndex 之后，第一个真正影响业务的痛点不是 prompt 工程、不是 RAG 召回，而是——**对话长了 Agent 就变傻。**

业务侧的具体表现是：

- 客服 Agent 跟用户聊到第二十轮，开始忘掉用户在第二轮告诉它的偏好
- 编程助手做一个稍长的项目，重启进程后完全不记得之前讨论过的架构决策
- 做工具型 Agent，每次新会话都要把背景信息再贴一遍，效率被反复重置

很多人第一反应是"那就把 context window 调大一点"。但这条路在 2025 年中段已经被反复证伪——**长上下文不是记忆系统**，这两件事的工程边界完全不同。

而你每天打交道的几个工具——Claude Code、OpenClaw、Cursor——之所以能做一周的项目还记得需求、升级版本后还能跑你之前的工作流，**关键不仅仅在于 LLM 多强，而在于它们各自配了一套显式的 Agent 记忆系统。**（上下文即一切）

顶流工具的"记忆"设计

Claude Code 的 CLAUDE.md + Auto Memory

Claude Code 是 Anthropic 官方的命令行 Agent 编程工具。

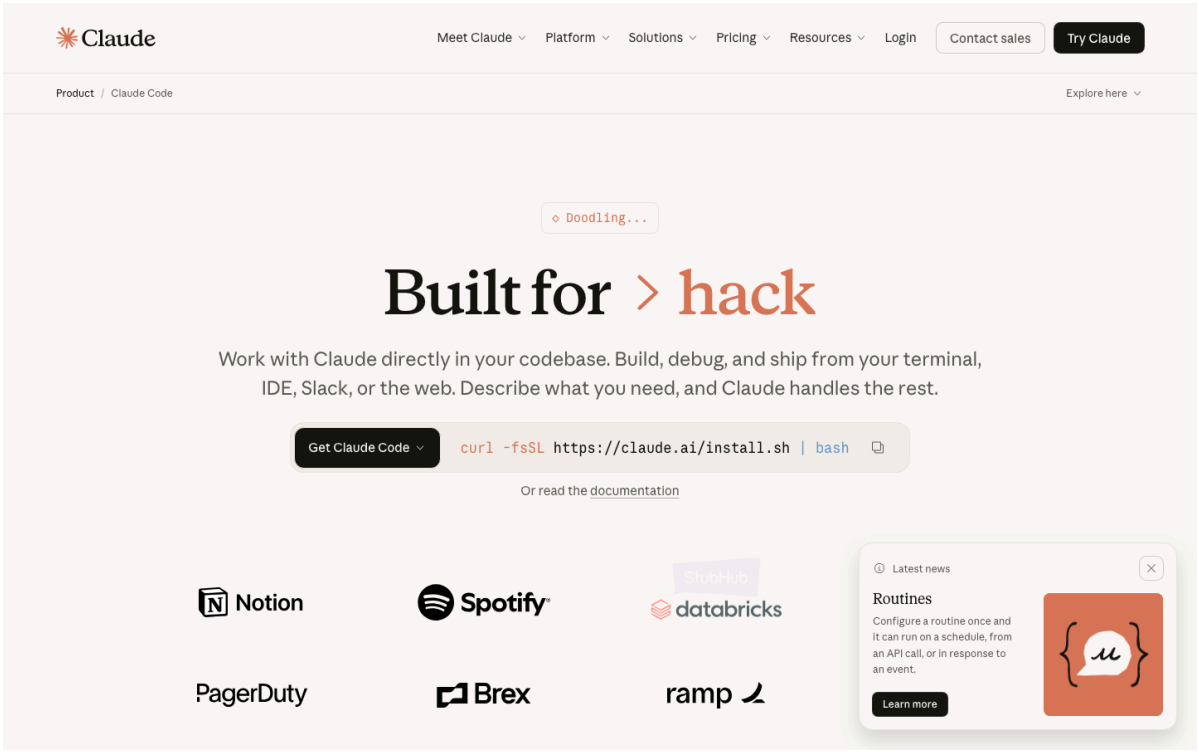

它的记忆设计是「**人写给 Claude 的指令** + **Claude 写给自己的笔记**」双轨：

- `CLAUDE.md` 是人手动维护的指令文件，分四个作用域：**Managed policy**（组织级策略，IT 部署）、**User**（`~/.claude/CLAUDE.md`，个人偏好）、**Project**（`./CLAUDE.md`，团队共享）、**Local**（`./CLAUDE.local.md`，本机私有）。同一项目内 Claude Code 还会沿目录层级向上逐层叠加 `CLAUDE.md`，让子目录可以局部覆写
- Auto Memory 是 Claude 自己根据用户的纠正与偏好不断追加的笔记，存储在固定路径 `~/.claude/projects/<project>/memory/`，启动时只读取 MEMORY.md 前 200 行（或 25KB）

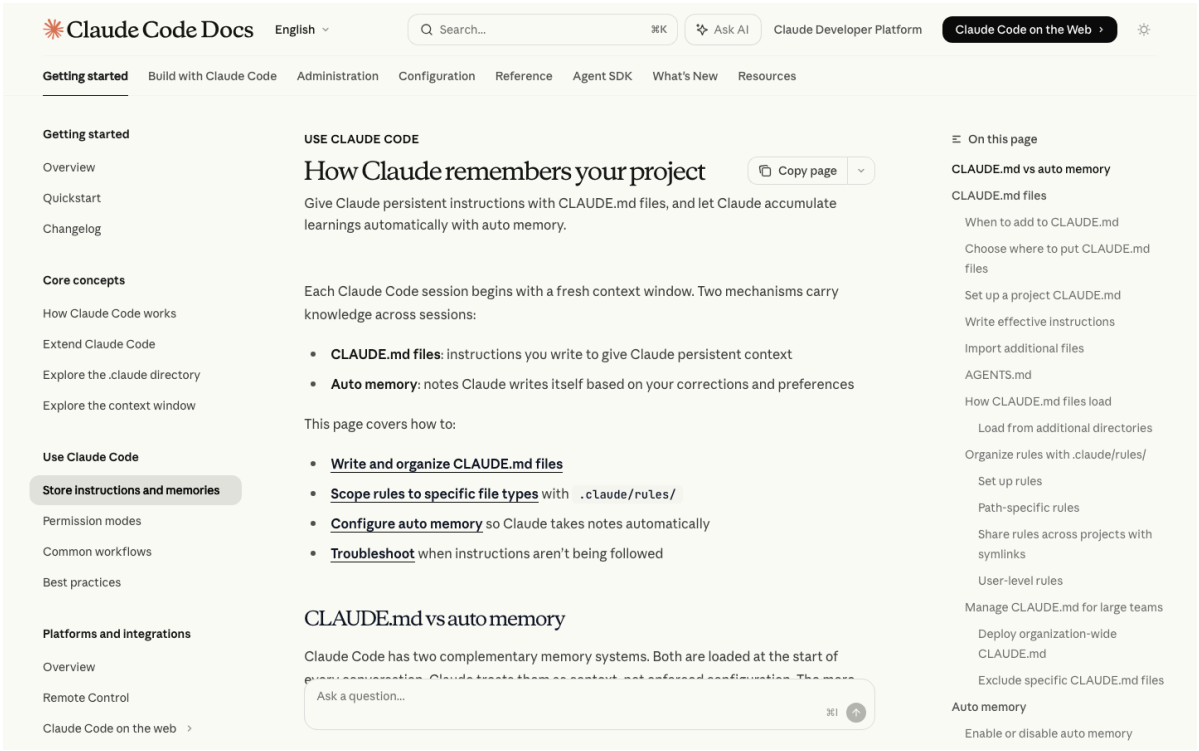

> 你新建一个项目时第一件事写的那个 `CLAUDE.md`，本质上就是 Claude Code 的「持久化记忆载体」——它选择了**用 markdown 文件作为记忆的真相源。**

OpenClaw 的 MEMORY.md / SOUL.md / HEARTBEAT.md

OpenClaw 是 2025-2026 国内学员熟悉度最高的开源 AI 助手之一（GitHub 37.2 万 stars，截至 2026-05-14 实测）。

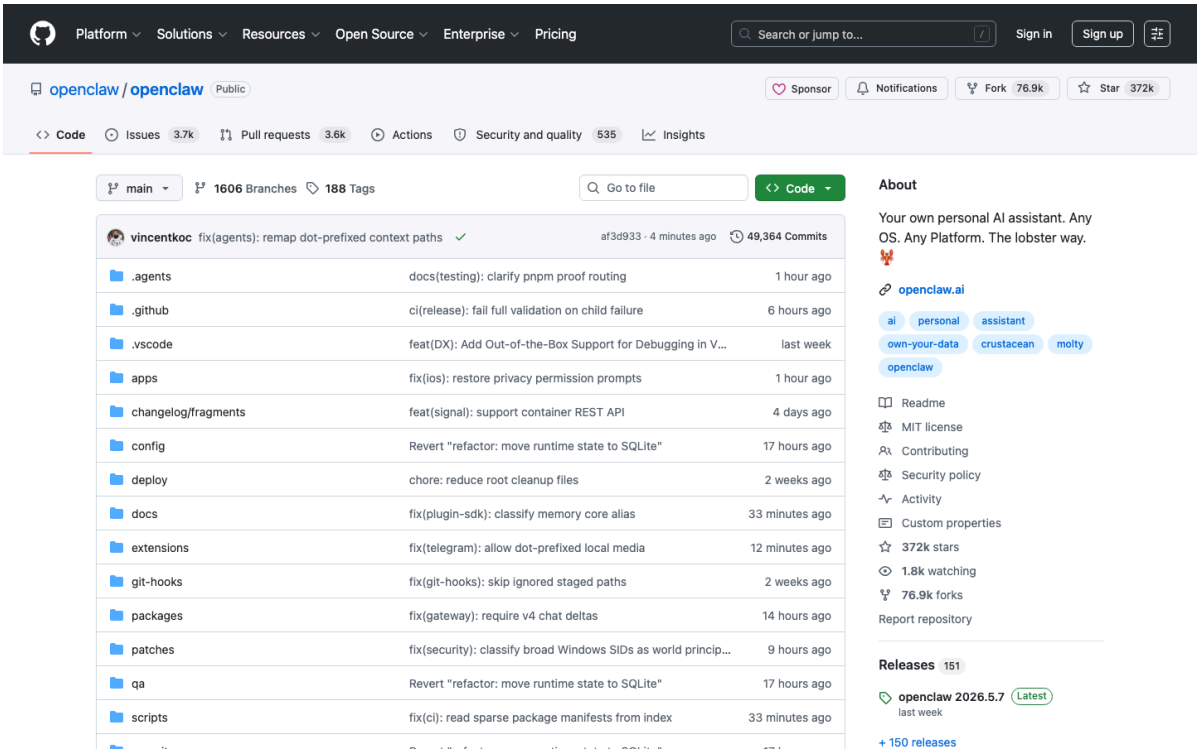

它的记忆设计在 Claude Code 之上做了进一步拆分：

- `MEMORY.md`：精炼的长期知识库（决策、人际、项目级上下文）
- `SOUL.md`：人格 / 价值观 / 约束
- `AGENTS.md`：操作规则、安全边界
- `HEARTBEAT.md`：定时任务调度
- `memory/YYYY-MM-DD.md`：每日工作记忆，会话开始时自动读取昨天和今天的笔记

这里说的"笔记"具体指什么？OpenClaw 把两类内容都当作"笔记"对待——**Agent 与用户的对话历史**会被 Agent 在会话间隙摘要追加到 `memory/YYYY-MM-DD.md`；**操作员手动维护的项目笔记 / 决策记录 / 文档**则直接写在 `MEMORY.md` / `SOUL.md` 等结构化 markdown 文件里。两类笔记最终都是文件系统里的 markdown 文本，没有"数据库表"概念。

OpenClaw 在这些 markdown 文件之上叠了一层向量索引——把每篇笔记按约 400 token（一个 token ≈ 一个英文词或半个汉字）切成片段（chunk），片段之间留 80 token 的重叠（overlap）以避免上下文断裂，所有向量存到 SQLite 数据库的 sqlite-vec 扩展里，让记忆查询既能精确读原文件、又能语义检索。

> 这两个工具的共同点是——**没有把记忆藏在数据库里**，而是把它放在文件系统中、用 markdown 表达、让操作员可见可编辑可版本控制。这个设计选择不是巧合，它代表了一整个流派：**文档派**。

三派全景概述

学员熟悉的几个工具分别属于不同的流派。这正是本课要建立的全景认知：

流派	通俗记法	顶流案例	代表项目
自动管家派	让后台 LLM 偷偷整理记忆	（消费者级 chatbot 大量在用）	**Mem0**（55.6k ⭐）
OS 派	让 LLM 自己把记忆"换入换出"（借用操作系统的 page in/out 思路）	（MemGPT 论文血统）	**Letta**（22.7k ⭐）
文档派	markdown 文件就是真相源	Claude Code、OpenClaw、Karpathy LLM Wiki、Cursor Rules	**GBrain**（15.5k ⭐）

> 三派的具体对比、设计哲学、代表项目实操，从下一节开始逐一展开。本节只建立一个朴素直觉——**你每天用的工具背后都有一套记忆系统**，它们不只是"LLM 调用得多"。

本集涉及的内容范围

本集（上集）覆盖三个具体产出：

1. **一张三大流派对比表**——把 Mem0 / Letta / Zep / LangMem / GBrain / Anthropic Memory Tool 这些项目按设计哲学归类，便于团队选型时快速对照
2. **三个代表项目的本地部署 + 核心功能实操**——Mem0 / Letta / GBrain 围绕同一组用户角色（Alice / Bob / Carol 三位 Python 工程师）的真实工作场景，亲手看到三种流派对同一类信息的不同存储形态。
3. **顶流工具记忆系统归类**——Claude Code、OpenClaw 早期、Karpathy LLM Wiki、Cursor 各自属于哪一派、为什么这么设计

下集（Part 3）会基于这三个产出再向前一步——给出一份**可在三种记忆后端之间切换的 web 对话产品**完整源码（GitHub 公开）。下集预计 **2-3 周内开课**，具体日期与开课通知见 §5a 末段的扫码留资入口。

§1b Agent 记忆是什么：与 Context Engineering / RAG 的区别

一句话定义

Agent 记忆系统（Agent Memory）= **持久的、自我演化的、跨会话的外部状态管理层。**

把这个定义拆开看：

- **持久**：数据落到 LLM 推理周期之外的存储里（数据库 / 文件系统 / 向量库），进程重启不丢
- **自我演化**：内容会随 Agent 与用户的交互不断 ADD / UPDATE / DELETE，不是只读静态资产
- **跨会话**：新 session 开启时能恢复，不依赖把所有历史塞进 prompt
- **外部状态**：相对于 LLM 本身的"参数权重"和"prompt 上下文"而言的第三类状态

> 把 Agent 比喻成人：LLM 是大脑、prompt 是当前正在想的事、Agent 记忆是大脑外的笔记本。脑容量有限、注意力有限，所以人类需要笔记——LLM 也需要。

三者关系：Agent 记忆 ≠ Context Engineering ≠ RAG

学员第一次接触这三个概念，最容易把它们混作一谈。但在工程上它们的边界、目标、生命周期完全不同。

维度	Context Engineering	RAG	Agent 记忆系统
本质	当前推理调用的 prompt 组装策略	静态文档检索 + 注入 prompt	持久的、可演化的外部状态层
生命周期	单次调用（请求一结束就消失）	单次查询（每次重新检索）	跨调用、跨会话、跨进程持久化
数据来源	用户当前消息 + 系统 prompt + 工具结果 + 历史对话	预先准备好的文档库（不变）	与用户交互过程中**动态产生**的事实 / 笔记
谁在写	系统提示工程师 / 调用方	文档准备阶段（人或 ETL 数据管道）	Agent 自己（自动管家派 / OS 派）或 操作员（文档派）
解决的问题	在有限 context 里塞最多信息	让 LLM 用上 prompt 没有的领域知识	让 Agent 跨会话"记得用户" / "记得自己上次在做什么"
典型场景	"把 RAG 结果 + 工具描述 + 历史压缩到 50k tokens"	"客服机器人查产品手册"	"客服 Agent 记住每个用户的偏好"

> 一种更简洁的表述：**Context Engineering 管"放什么进 prompt"，RAG 管"从静态库里查什么放进 prompt"，Agent 记忆管"动态积累什么、什么时候放进 prompt"**。三者是协作关系，不是替代关系。

一个常见误区：长上下文 ≠ 记忆系统

LLM 的 context window 越来越长（Gemini 1.5 Pro 1M、Claude Opus 4.6 在 1M token 也宣称可用），自然会有人说："context 都 100 万 token 了，记忆系统还有什么必要？把对话历史全塞进去不就完了？"

这个看似合理的推论在工程上跑不通。原因有三层：

层 1：context rot 问题（attention 不是均匀分布）

context rot（上下文腐化）指**随 prompt token 数增加、模型对长上下文中特定信息的召回准确率持续下降**的现象。Anthropic 2026 官方研究和 Chroma 的 Context Rot 实验反复确认这一点——而且任务越复杂下降越严重。Anthropic 官方原话："context 必须被当作一种**有限资源 + 边际收益递减**的东西来管理"。即便是 Claude Opus 4.6 在 1M token 上的 MRCR v2（Multi-needle Retrieval v2，长上下文多目标精确召回基准）准确率也只有 76%（相对 Sonnet 4.5 的 18.5% 已是 4 倍提升，但远谈不上"完美召回"）。

层 2：成本与延迟（百万 token 不可持续）

每次调用塞入百万级 token 的 prompt：

- 推理成本按 token 线性涨（百万 token 调用单价远高于"先检索 1k token 相关记忆再调用"）
- 首 token 延迟显著增加（attention 矩阵规模二次方增长）
- 在交互式应用中（聊天 / 编程助手 / 客服）这种延迟无法接受

> Mem0 论文给出的实测对比：full-context 方法 p95 延迟 17.117 秒，Mem0 p95 延迟 1.440 秒——**降幅 91%**。来源：arXiv 2504.19413。

层 3：哲学边界（context 是瞬时态、记忆是持久态）

即使 context window 无限长、推理免费，**context 仍然是单次调用的瞬时态**。新 session 开启时它消失。Agent 记忆要回答的问题不是"如何在一次推理里塞更多信息"，而是"如何让信息**跨调用、跨进程、跨周**留下来"。这是两个工程问题，长上下文回答不了第二个。

> 这个误区还有一个反向版本——"我已经有 RAG 了，记忆系统就不用了"。同样不对。**RAG 是查静态文档，记忆是查动态产生的事实**。客服 Agent 的产品手册放 RAG，用户偏好放记忆，二者各司其职。

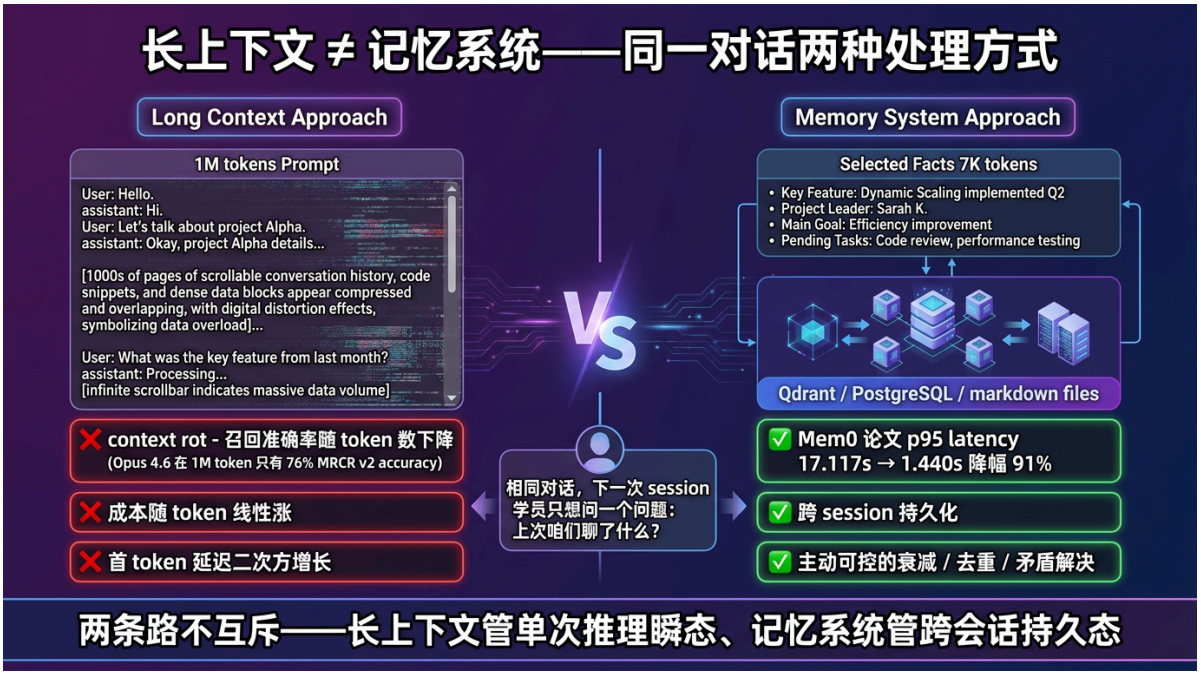

三者协作的典型架构

下图展示了一个成熟 Agent 系统中三者如何协作：

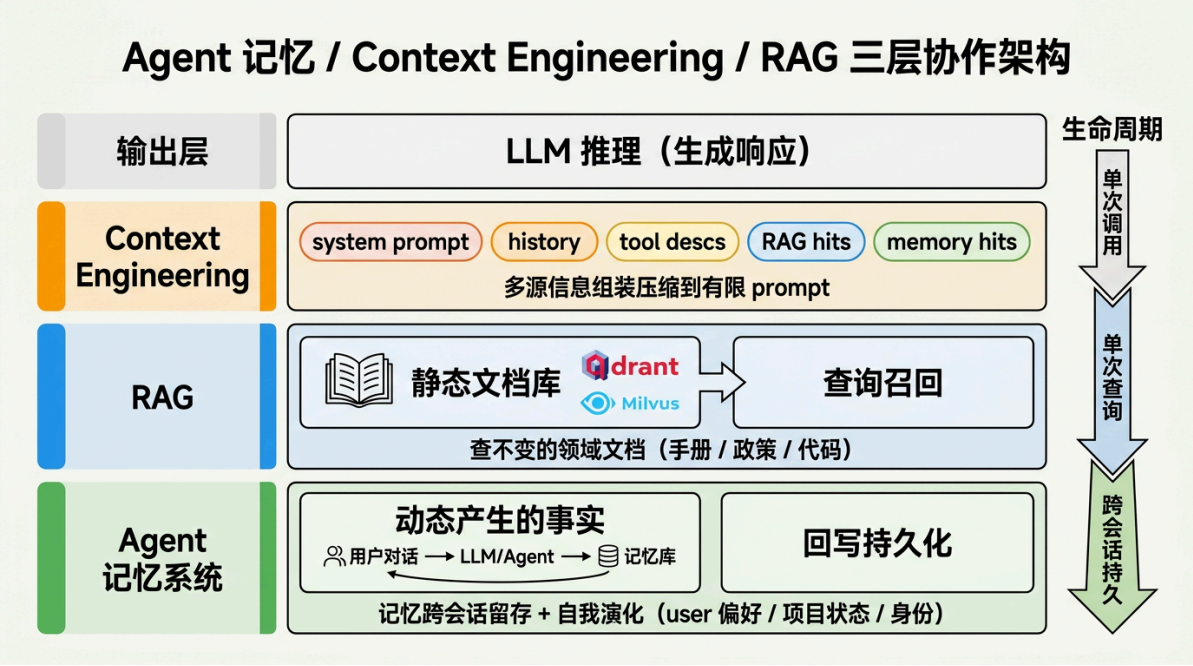

在一次完整调用中：

1. **Agent 记忆层**：根据当前 query 从持久化记忆（数据库 / 文件系统）中召回相关条目
2. **RAG 层**：从静态文档库中召回相关段落
3. **Context Engineering 层**：把上述两类结果 + 历史对话 + 工具描述 + 系统 prompt **组装压缩**成最终的 prompt（控制在合理 token 数内）
4. **LLM 推理**：基于这个组装好的 prompt 生成响应
5. **回写记忆层**：调用结束后，把本轮交互产生的"值得记住的事实"写回 Agent 记忆层（自动管家派由后台 LLM 抽取、OS 派由 Agent 主动写、文档派由 Agent 操作 markdown 文件）

> 这是一个简化模型——实际系统中三层之间还有更多变体（如 RAG 也可以查记忆、Memory 也可以做语义索引）。但理解这个分工是后续选型的基础。

本节涉及的核心概念

概念	一句话定义
Agent 记忆系统	持久的、自我演化的、跨会话的外部状态管理层
Context Engineering	把多源信息（query / 工具 / 历史 / 检索结果）压缩组装到有限 prompt 的策略
RAG	Retrieval-Augmented Generation，从外部静态文档检索后注入 prompt
context rot	随 prompt token 数增加、模型对长上下文中特定信息的召回准确率下降的现象
MRCR v2	Multi-needle Retrieval benchmark v2，衡量长上下文中多目标精确召回能力

§1c RAG 做记忆的局限：从 OpenClaw 早期 memory.md 看演进

学员认知锚点

国内做过 Agent 项目的工程师，几乎都做过 RAG。最常见的实践是：把领域文档切片 → 灌进向量库（Qdrant / Milvus / FAISS / Chroma 任选其一）→ 加一道关键词检索 BM25 → 把两路检索结果合并（混合检索）→ 拼到 prompt 里给 LLM 看。

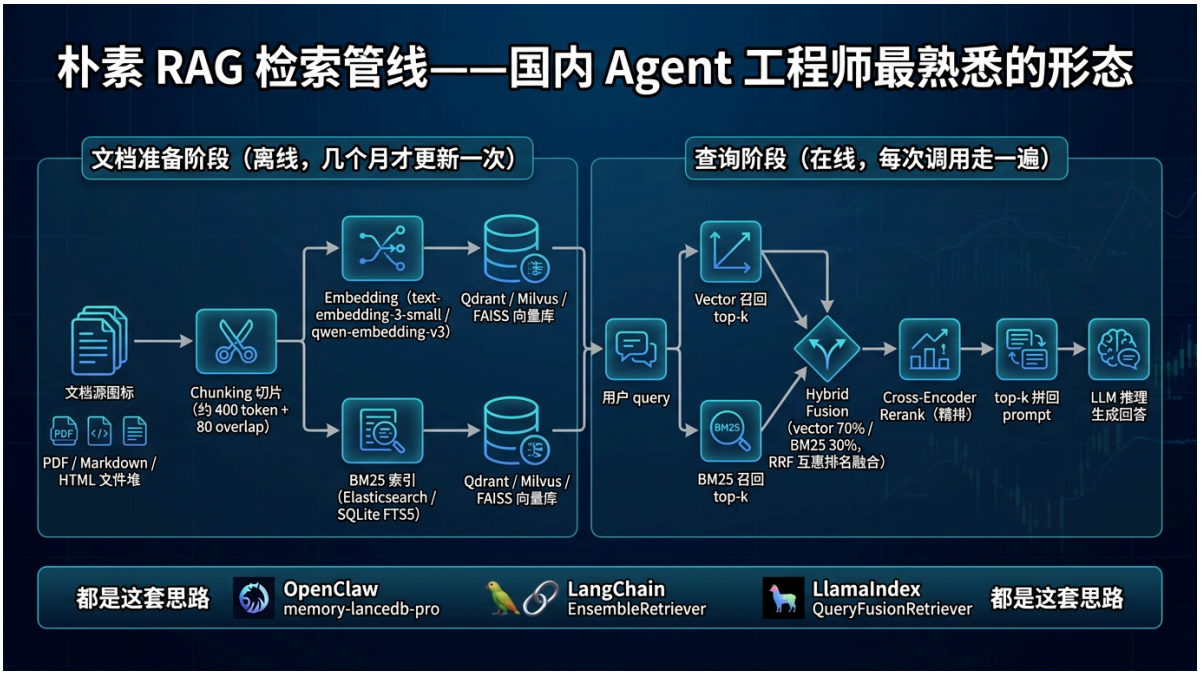

> 「混合检索（hybrid retrieval）」= 向量召回（语义相似）+ BM25（关键词精确匹配）+ 加权融合。生产中常用比例是 vector 70% / BM25 30%，OpenClaw 的 memory-lancedb-pro 插件、LangChain 的 EnsembleRetriever、LlamaIndex 的 QueryFusionRetriever 都是这个思路。融合阶段常用 **RRF**（Reciprocal Rank Fusion，互惠排名融合——按各路结果的排名倒数求和，避免不同打分尺度直接相加），融合后再用 **Cross-Encoder rerank**（交叉编码器重排——把 query 和候选文档拼一起送 encoder 一次性打分，比单独编码更准但更贵）做精排。

很多人第一次想"给 Agent 加记忆"，第一反应就是——**把对话历史也当成文档，灌进同一套 RAG 管线不就行了？**

这条路在工程上能跑起来，OpenClaw 早期的 `memory.md` 就是这个思路的代表实现。但跑起来不等于能解决问题——把 RAG 直接当记忆系统用，会撞上几堵结构性的墙。本节把这条演进路径完整拆开。

阶段 1：朴素方案——memory.md + 混合检索

OpenClaw 早期版本（2026 年初）的记忆方案非常朴素：

- **载体**：一个 `memory.md` 文件（或 `memory/` 目录下若干 markdown 笔记）
- **写入**：每次会话结束，由 Agent 自己把"值得记住的事"追加到 markdown
- **索引**：把 markdown 切片（约 400 token / chunk + 80 token overlap）灌进 SQLite + sqlite-vec（SQLite 的官方向量扩展，让普通 SQLite 数据库直接支持向量相似度查询）
- **检索**：query 来时走混合检索——vector 0.7 + BM25 0.3，top-k 拼回 prompt

这套方案有一个看似自洽的优点：**它和你已经熟悉的 RAG 长得一模一样**，几乎零认知成本就能搭起来。

实测它能解决的问题：

- 长对话被截断后，Agent 仍能搜出几周前的对话片段
- 跨 session 下，新会话开始时能召回历史决策
- 部署简单——SQLite + 一个 embedding 模型就够了

> 这个方案在小团队 / 个人 brain 场景下到今天仍然有效。OpenClaw 的 memory-lancedb-pro 插件（vector 0.7 / BM25 0.3 + RRF 融合 + Cross-Encoder rerank）就是这条路线的工程化加厚版本。来源：github.com/CortexReach/memory-lancedb-pro。

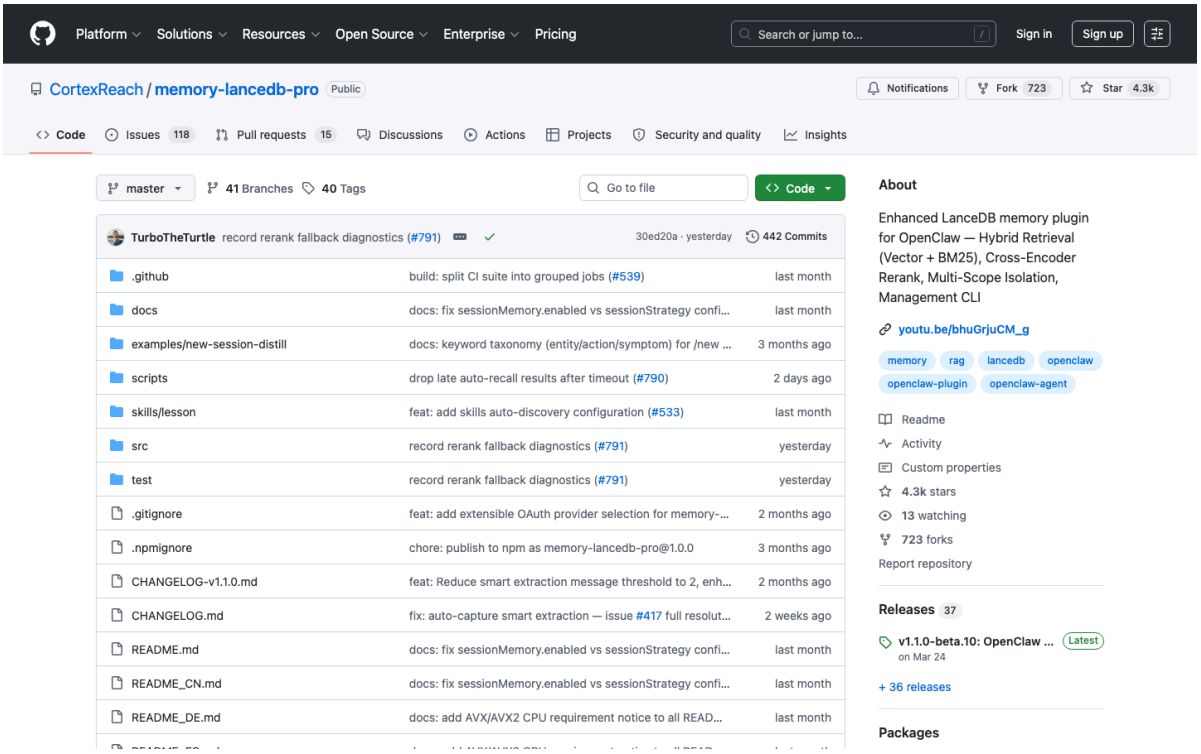

阶段 2：撞墙——RAG 做记忆的四个结构性局限

朴素方案跑一段时间后，几个结构性问题会浮现。这不是工程实现没做好，而是 **RAG 模型本身的设计前提与"记忆"场景不匹配。**

局限 1：RAG 假设"文档库基本不变"，记忆是动态产生的

RAG 的标准用法是查"产品手册""政策文档""技术文档"——这些文档**先写好、后查询**，几个月才更新一次。

记忆完全相反——它**在 Agent 与用户的每一次交互中产生**：

- 用户偏好（"我喜欢简洁回答"→"我又改主意了，要详细一点"）
- 项目状态（"今天讨论了架构 A"→"明天否决了 A 改用 B"）
- 用户身份（"我叫 Alice"→"换工作了，现在叫 Alice Wang"）

把这些**动态、矛盾、有时序的事实**当成"文档"灌进 RAG，会撞上下一个问题：

局限 2：RAG 没有写入策略，"灌什么进去"是个未解决问题

RAG 文档准备阶段有一道明确的工序——**人或 ETL 决定哪些文档进库、按什么粒度切。**

但记忆场景下没有这道工序。Agent 与用户对话产生的内容**默认全部都是潜在记忆**：用户消息、Agent 回复、工具调用结果、系统消息……朴素 RAG 方案要么全灌（必然爆炸）要么全不灌（等于没记忆）。

如果选"按规则灌部分"，下一个问题是 **决定灌什么的规则又由谁来写**：

- 让人写规则 → 维护成本高、规则覆盖不全
- 让 LLM 自动判断 → 这恰好就是 Mem0 的"自动管家派"路线（见 §1d / §2）
- 让 Agent 主动用 tool 调写 → 这就是 Letta 的"OS 派"路线
- 让操作员手动维护 markdown → 这就是文档派的现代演进

> 也就是说——**当代三大记忆流派的出现，本质上都是在回答 RAG 没回答的"写入策略"问题。**

局限 3：没有冲突解决，矛盾事实会同时召回

举个具体场景。Alice 第一次说"我做后端开发"，第二个月跳槽说"我现在做 AI 算法"。朴素 RAG 把两条都灌进库，下一次问"Alice 是做什么的"——召回结果同时包含两条**互相矛盾的事实**，Agent 很可能给出错误回答。

成熟的记忆系统都有显式的冲突解决：

- Mem0 的 LLM tool call 在 ADD 之前会判 UPDATE / DELETE / NOOP——找到语义相似的旧记忆，比较"信息含量"决定是替换还是新增
- Zep 用 **bi-temporal**（双时间轴）模型给每条事实打"有效时间窗"——同时记录"事实何时被写入"和"事实何时在现实中生效/失效"两条时间线，旧事实被标记为 invalid 但物理保留（便于时序追溯）
- Letta 把核心事实放在固定大小的 working context block 里，agent 主动调用 `core_memory_replace` 覆盖旧值
- 文档派靠 markdown 文件天然的"覆盖即生效"——Agent 改一行就是改了

朴素 RAG 没有任何这类机制，**它只会越灌越多。**

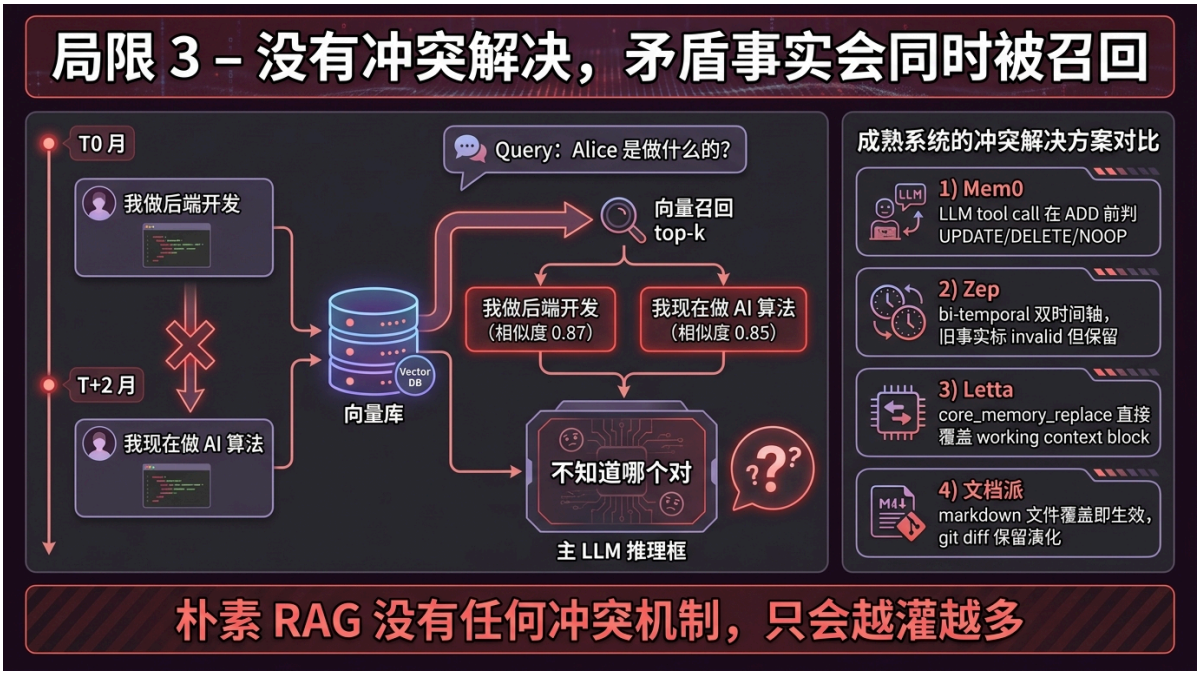

局限 4：没有遗忘策略，召回噪声会越积越大

> 这是 RAG 做记忆**最有杀伤力的局限。**

Mem0 自己（一个比朴素 RAG 设计严谨得多的系统）发布后被社区做过一次广为人知的审计——某个用户在生产中跑了 32 天，累计了 **10134 条记忆**，逐条人工分析后发现 **97.8% 是垃圾**——只有 38 条原样可用。来源：mem0ai/mem0 issue #4573（提交者 @jamebobob，2026-03-27）。issue 给出的 5 类 junk 精细分布：**52.7% 是 boot file 重复抽取、11.5% 是 heartbeat 噪声、8.2% 是系统架构倾倒、7.4% 是瞬时状态、5.2% 是幻觉用户档案。**提交者另在评论区指出"升级到 Sonnet 4.6 不能降低 junk 比例"——根因是默认 prompt 而非 LLM 能力。该用户随后 fork 一份并加入 conditional persistence（用户确认才存）作为补救。

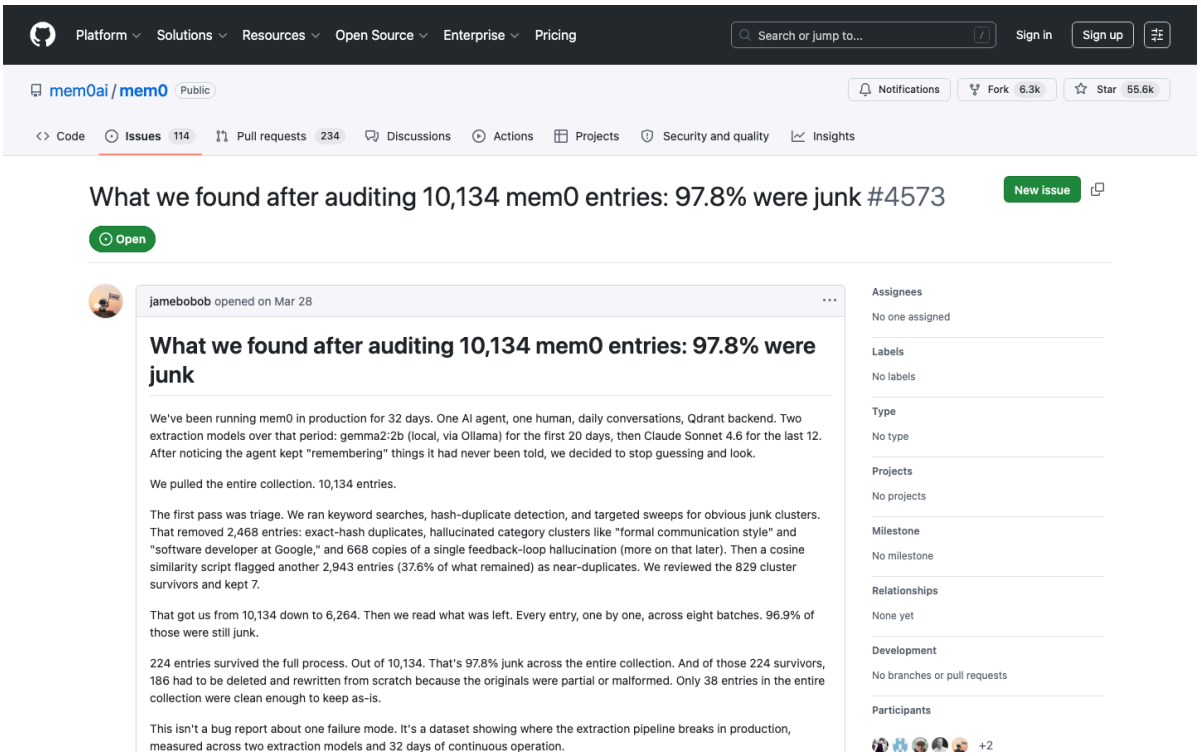

垃圾来源被定位为三个：

1. 召回的记忆又被喂回抽取阶段，形成**反馈环**——同一条事实（如 "User uses she/her pronouns"）反复被重抽存入
2. Mem0 默认的 `FACT_RETRIEVAL_PROMPT` 写了 7 个抽取类别，等于"把对话里所有结构化信息都抽出来"——心跳 / cron 日志 / NO_REPLY 标记 / 系统配置全被存
3. **缺乏 pre-storage 过滤**——任何对话片段都默认被认为"值得记住"

这是一个比朴素 RAG 设计严谨得多的系统都会踩的坑。如果只是把对话历史灌进 RAG 而**完全没有遗忘机制 / 重要性评分 / 衰减函数**，召回质量会更快崩溃。

> Generative Agents（斯坦福小镇 25 个 NPC，UIST 2023）留给行业最大的遗产是一个三因子检索公式——`score = α_recency × recency + α_importance × importance + α_relevance × relevance`，其中 `recency = exp(-decay × hours_since_last_access)` 是显式的时间衰减、`importance` 由 LLM 在写入时打 1-10 分。后续 Mem0 / A-MEM 的检索几乎全部继承了这个三因子框架。**朴素 RAG 只有第三项 relevance**——这就是为什么把对话历史直接灌进 RAG 会越积越乱。

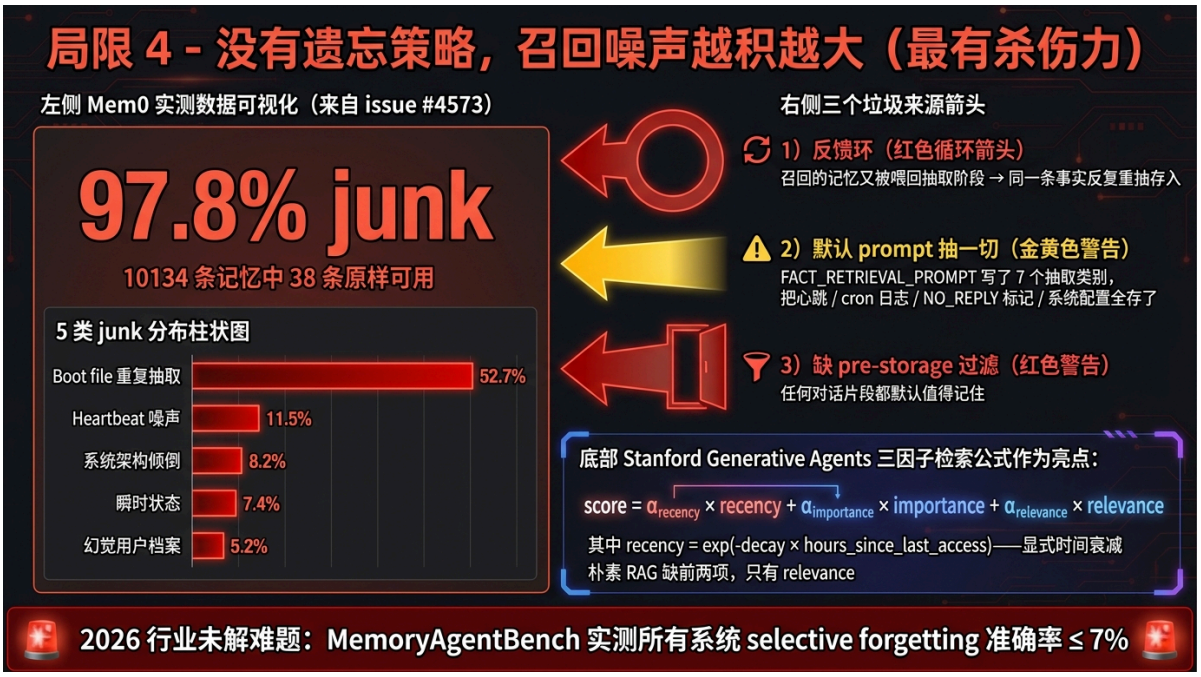

阶段 3：演进——OpenClaw 的现代记忆架构（2026 年中）

OpenClaw 的记忆系统在过去半年里发生了一次较彻底的演进。把当前（2026-05）的样子和 2026 年初的朴素 memory.md + RAG 对比，能看到文档派**在四个结构性局限上分别做了什么工程响应**——这是一个学员熟悉的真实系统，正好用来理解"文档派如何对抗 RAG 局限"。

演进 1：从单层文件到三层 promotion/demotion

OpenClaw 当前的记忆分三层（官方文档）：

- **Core 层**：`MEMORY.md` / `SOUL.md`——长期 curated 知识，每次 session 启动加载到 prompt 顶部
- **Working 层**：`memory/YYYY-MM-DD.md` 每日工作笔记 + `active-context.md` 当前任务上下文——Agent 间歇会话间共享
- **Peripheral 层**：通过 hybrid 检索按需召回的历史片段、wiki 页面、向量索引中的 chunk

三层之间有**自动 promotion / demotion**——长期高频访问的事实会被 Agent 主动升格到 Core 层，长期未访问的内容会降到 Peripheral。这是文档派**对 §1c 局限 3 冲突解决**的一种回答：用"层级"代替"覆盖"，让重要事实自然向上沉淀。

演进 2：从单一 engine 到多 memory engine 可插拔

OpenClaw 2026.3+ 的 plugin 架构（`before_prompt_build` hook，取代了已废弃的 `before_agent_start`）允许第三方 memory engine 无缝接入。生态里目前活跃的至少有 6 个：

Memory engine	路线	关键能力
`builtin`（默认）	SQLite + sqlite-vec	零配置、上手最快
`memory-lancedb-pro`（CortexReach）	LanceDB	hybrid（vector 70% / BM25 30%）+ Cross-Encoder rerank + recency scoring
`memory-wiki`（OpenClaw 官方）	编译式 wiki vault	`wiki_search` / `wiki_get` / `wiki_apply` / `wiki_lint` 一致性检查
`ClawMem`（yoloshii）	Hooks + MCP	QMD 多信号检索（BM25 + vector + RRF + query expansion + cross-encoder rerank）+ MAGMA 意图分类

Memory engine	路线	关键能力
`MemOS Cloud`（MemTensor）	AI-native 跨 session 记忆	textual / activation / parametric 三类记忆
`Cognee`（官方集成）	Knowledge graph + memory + RAG	关系抽取 + 实体融合

学员选型时不再是"用 OpenClaw 的记忆 vs 不用"，而是"用哪个 engine"——这正是文档派**对 §1c 局限 2 写入策略**的工程化回答：把"灌什么进去"作为可插拔策略让用户自己选。

演进 3：从全文检索到 hybrid + 衰减 + 重排的完整流水线

OpenClaw 当前的标准检索流水线（LanceDB 官方博客）：

```
Vector 召回 → BM25 召回 → Hybrid Fusion (vector 70% / BM25 30%, RRF)
            → Cross-Encoder Rerank → Lifecycle Decay → 噪声 Filter → top-k
```

其中 **Lifecycle Decay** 用的是 **Weibull 衰减**——高频 / 高重要性的记忆排名上浮，长期未触达的记忆排名下沉。这是文档派**对 §1c 局限 4 遗忘策略**的尝试（行业里这个局限还没完全解决，OpenClaw 是少数把"显式衰减函数"工程化的实现之一）。

演进 4：从全平铺到 12 层语义索引

社区项目 openclaw-memory-architecture 在 OpenClaw 基础上扩展出了**12 层记忆架构**——含 3K+ facts 的知识图谱、multilingual 语义搜索（7ms GPU 延迟）、continuity / stability / graph-memory 三个互补插件、activation/decay 系统、domain RAG。

这套架构的具体细节超出本课范围，但**它的存在本身证明了一件事**——文档派不是"原始 markdown"，它的工程上限远比 §1c 阶段 1 那个"朴素 memory.md + RAG"高得多。

小结：OpenClaw 当前的全貌

把这四条演进合在一起看：OpenClaw 当前的记忆系统是「**多层 markdown 文件 + 多 engine 可插拔 + hybrid 流水线 + 显式衰减**」的复合体——但它**仍然是文档派**，因为：

- 载体仍是文件系统（markdown 是真相源）
- 操作仍以显式工具调用 / hook 触发为主（不是后台 LLM 偷偷抽）
- 操作员（人）仍可直接读写文件（与 Agent 共享真相）

这是文档派的工程化巅峰之一——和 Mem0「后台 LLM 自动抽取」、Letta「OS 类比 + Memory Pressure」是**三个完全不同的设计哲学**。下一节会把这三派的对应关系彻底拆开。

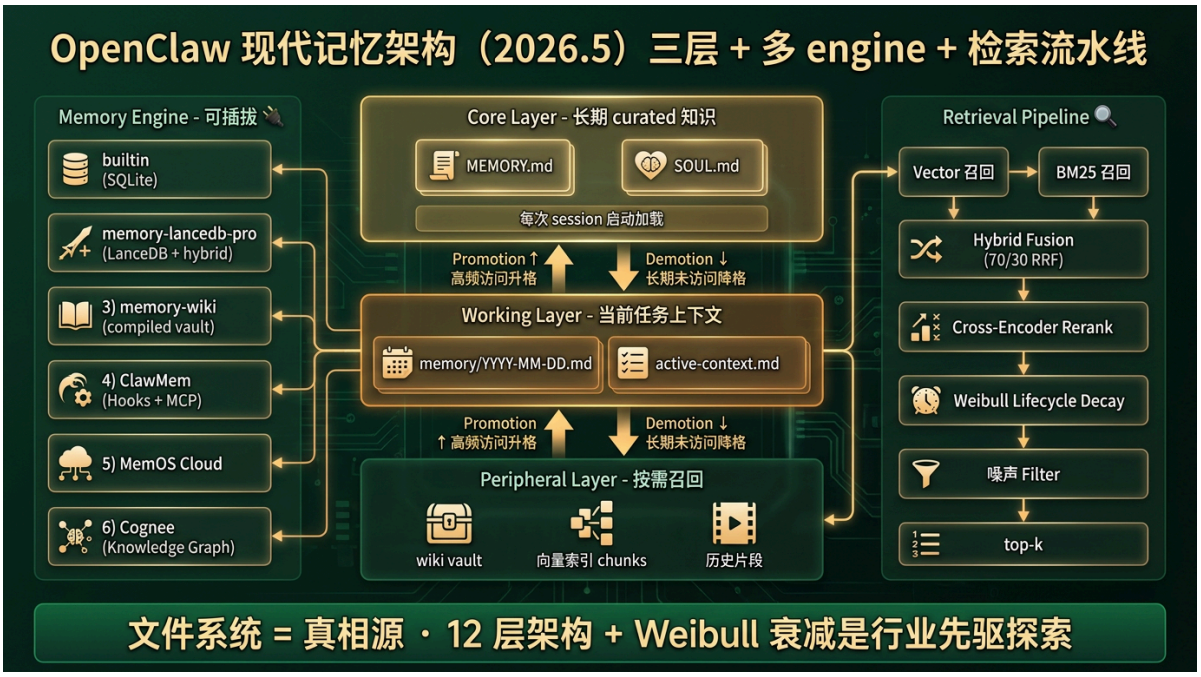

RAG 之外的当代记忆系统：五条路线全景

RAG 撞墙之后，业内分头探索出了**五条主路线**。差异看似复杂，本质上都在回答同一个问题——**这份"病历"该由谁来写、按什么格式写、什么时候清理。**

用一个生活化比喻：把对话当作病人陈述，把"记忆"当作病历，五种"写病历"的方式正好对应五条路线：

```
病人（用户）说：「这周头疼，上周已经好了一半，但今天又复发了。」
                              ↓
        ┌──────────┬──────────┬──────────┬──────────┬──────────┐
   ① 堆挂号单   ② 雇 AI 助理   ③ 医生自己写   ④ 模板填空   ⑤ 双时间戳
   （静态 RAG）  （自动管家派）   （OS 派）     （文档派）   （temporal-graph）
```

- **① 静态 RAG 当记忆**：所有挂号单原样堆在一起，每次查询翻箱倒柜。便宜但乱。
- **② 后台 LLM 自动抽取**：雇个 AI 助理在背后默默把对话整理成结构化病历。省心但黑盒。
- **③ Agent 主动 tool 写**：让医生（Agent）自己每次决定"这条值得写进病历"。精确但累。
- **④ 结构化文档**：用印好的病历模板，每个字段必填、可校验、可 lint。透明但要前期设计。
- **⑤ temporal-graph**：每条诊断都标"何时确诊、何时失效"双时间戳。最严谨但维护贵。

把这五条路线和上一节四个局限的解决程度对照如下：

路线	通俗类比	代表项目	核心改动	解决了 §1c 的哪些局限
静态 RAG 当记忆	堆挂号单	朴素 memory.md + hybrid 检索	无	起点——只解决"召回历史"，局限 1-4 都未解决

路线	通俗类比	代表项目	核心改动	解决了 §1c 的哪些局限
后台 LLM 自动抽取	雇 AI 助理	Mem0 / LangMem-background / A-MEM	抽取 → ADD/UPDATE/DELETE/NOOP 决策	局限 2 写入策略 + 局限 3 冲突解决
Agent 主动 tool 写	医生自己写	Letta / Anthropic Memory Tool / LangMem-hot-path	Agent 自己调 `core_memory_replace` / `archival_memory_insert`	局限 1 动态产生 + 局限 2 写入策略
结构化文档	模板填空	GBrain / OpenClaw（含 memory-wiki / Lifecycle Decay）/ Anthropic Skills	把 markdown 升级为带 schema 的 claim + lint + 衰减	局限 2 写入策略 + 局限 3 冲突解决 + 局限 4 的部分缓解
temporal-graph	双时间戳	Zep / Graphiti	给每条事实加 bi-temporal 有效时间窗	局限 3 冲突解决（最严格的方案）

> 没有任何一条路线**完整解决了局限 4 遗忘策略**——这是 2026 行业最大的未解难题。MemoryAgentBench 的实测显示，所有现代记忆系统在"该忘的没忘"任务上的最高准确率只有 **7%**（绝大多数低于 5%）。Anthropic 在 Claude Code 上 quietly ship 了一个名叫 "Auto Dream" 的功能——定期 consolidate / dedup / prune——也仍然只是缓解。OpenClaw 的 Weibull 衰减是另一种工程化尝试（见上面 §1c 阶段 3）。

承上启下：温度计、X 光、CT、MRI 都是医疗设备，但功能完全不同——同样道理，上面五条路线虽然都叫"Agent 记忆系统"，但**它们的设计哲学差异比工程实现差异大得多。**下一节（§1d）会把其中**最主流的三条**——自动管家派、OS 派、文档派——通过一个"周末项目 + 一周后跨项目复用"的真实场景同台对照演示一遍。看完那一节，你就能直观理解为什么三派的差异不是 benchmark 数字能简单比较的。

§1d 三大流派对比：自动管家派 / OS 派 / 文档派

Mem0、Letta、Zep、LangMem、A-MEM、MemOS、MIRIX、Anthropic Memory Tool——只看名字会以为它们在抢同一块蛋糕，事实上它们对"什么是 Agent 记忆"的回答完全不同。当代 Agent 记忆系统按**设计哲学**收敛到三大流派：自动管家派、OS 派、文档派。

> 注：本表用「通俗名」而非学术译名。学术上更严谨的名称是 Memory Manager（自动管家派）、OS-style Memory（OS 派）、File-as-Memory（文档派），三者都来自 2025-2026 的工程文献与论文。

一个真实场景：周末项目 + 一周后跨项目复用

为了把三派的差异讲清楚，先看一段真实的对话——学员小张用 AI 编程助手做一个周末项目，然后下周再开新项目。整个时间线压缩在三天里，但**包含了 Agent 记忆系统四个最核心的挑战**：

时间	学员说什么	隐藏的记忆挑战
周六 09:00	"我想做个个人博客，对 Python 比较熟，部署喜欢简单的"	① **写入策略**：这段话里哪些是该记的？「博客」是项目状态、「Python 熟」是用户偏好、「简单部署」是约束条件——粒度怎么切？
周六 10:00	（AI 推荐 FastAPI + Docker）	—
周六 15:00	"FastAPI 部署太复杂了，改 Flask 吧"	② **冲突解决**：上午的「FastAPI 决策」怎么覆盖？是新增一条还是改旧的？
周日 10:00	"上次咱们最终用什么框架？数据库还用 PostgreSQL 吗？"	③ **跨 session 召回**：进程已经重启了一次，记忆还在不在？召回时矛盾事实会不会同时返回？
周日 14:00	"数据库再换 SQLite 吧，PostgreSQL 太重了"	②' **第二次冲突** + 决策链演化（FastAPI→Flask、PostgreSQL→SQLite）
周一 09:00（一周后）	"开始另一个项目，简单的 todo list，技术栈推荐？"	④ **跨项目复用**：博客项目结束了，下个项目还能记得「这个用户喜欢 Python + 轻量栈」吗？项目状态需要切换，但**用户偏好**应该跨项目延续

这五行对话隐藏了 Agent 记忆系统的全部核心问题——**写入策略 / 冲突解决 / 跨 session 召回 / 跨项目复用**。三派给出的答案完全不同。下面逐一拆解。

思路一：自动管家派 — 后台 LLM 偷偷整理事实库

机制：每次 `m.add(messages, user_id="zhang")` 调用，后台 LLM 把消息抽成结构化"事实"（fact）入库。下一次查询时通过向量检索召回相似事实，拼回主 LLM 的 prompt 里。学员看不见这个抽取过程——所谓"自动管家"。

写入路径（周末项目场景下的关键代码）：

```
# 周六 09:00 学员消息进入
m.add([{"role":"user", "content":"我想做个博客，对 Python 熟，喜欢简单部署"}],
      user_id="zhang")
# 后台 LLM 抽出 3 条 fact：
#   "User is making a personal blog"
#   "User is familiar with Python"
#   "User prefers simple deployment"

# 周六 15:00 决策变更
m.add([{"role":"user", "content":"改 Flask 吧"}], user_id="zhang")
# Mem0 V3 默认 ADD-only——保留旧 "decided FastAPI" + 新增 "decided Flask"
# 矛盾事实并存
```

```
# 周日 14:00 第二次决策变更
m.add([{"role":"user", "content":"数据库改 SQLite 吧"}], user_id="zhang")
# 又一条新 fact 入库——三条事实并存（PostgreSQL / SQLite / Flask / FastAPI）
```

读取路径（周日 10:00 学员问"最终用什么框架？" Agent 如何回答）：

```
# 主 Agent 收到学员问题
user_query = "上次咱们最终用什么框架？数据库还用 PostgreSQL 吗？"

# 第一步：调 m.search 召回相关事实
relevant_facts = m.search(user_query, filters={"user_id":"zhang"})
# 向量召回 top-5 按相似度排序（默认 V3 不带显式时间戳）：
# [
#   "User decided FastAPI"        (similarity 0.89),
#   "User decided Flask"          (similarity 0.87),
#   "User prefers simple deploy"  (similarity 0.72),
#   "User uses PostgreSQL"        (similarity 0.85),
#   "User changed to SQLite"      (similarity 0.83),
# ]

# 第二步：把召回 fact 拼回主 LLM 的 prompt
prompt = f"""用户问：{user_query}
已知事实：
{format_facts(relevant_facts)}
请回答用户的问题。"""

answer = main_llm.complete(prompt)
# 主 LLM 看到矛盾事实，凭"哪个更具体 / 哪个像最新决定"猜——
# 实测：框架问题答 Flask 的概率 ~70%，数据库问题答 SQLite 的概率 ~65%
# 失败时会回答 "你最初决定用 FastAPI" 或同时列举多个选项让用户确认
```

周一 09:00 新项目跨项目复用：

```
m.search("推荐技术栈", filters={"user_id":"zhang"})
# 偏好 fact（"User is familiar with Python"、"User prefers simple deployment"）
# 自动跨项目召回——同 user_id 共享，无需额外配置
# 但旧项目的具体决策（Flask/SQLite）也可能被召回 → 跨项目噪声
```

对四个挑战的表现：

挑战	表现	说明
① 写入策略	✅ 全自动	后台 LLM 决定抽什么、按什么粒度切
② 冲突解决	⚠️ 矛盾并存	V3 默认 ADD-only，主 LLM 召回时同时拿到 FastAPI + Flask（实测时序判断准确率 60-75%）
③ 跨 session 召回	✅ 持久化	事实库存在向量库，新 session 直接 `m.search()`
④ 跨项目复用	✅ 自动（含副作用）	同 `user_id` 下偏好自动共享，但旧项目噪声也会被召回

代价：黑盒——学员不知道 Mem0 默认抽什么、抽对没有。Mem0 在生产中跑 32 天可能堆 10134 条记忆其中 97.8% 是垃圾（§1c 局限 4），就是这种"无脑灌入"路线的副作用。

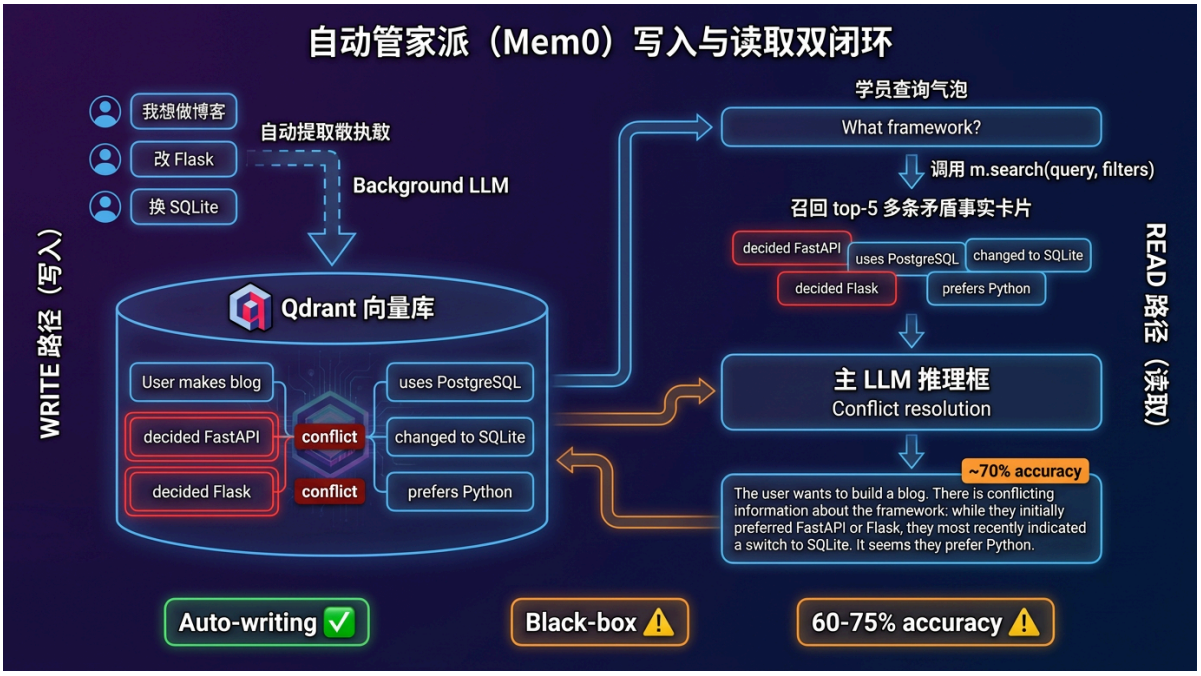

思路二：OS 派 — Agent 主动管"换入换出"

机制：把 LLM 的 context window 比作 RAM、外部数据库比作 Disk。Agent 自己用 function call 主动维护一个固定大小的 `working context block`——`core_memory_replace` 覆盖旧值、`archival_memory_insert` 存档不常用的事实、`archival_memory_search` 召回历史。Memory Pressure 触发时把不活跃内容 page out 到 archival。

写入路径（周末项目场景下的关键代码）：

```
# 周六 09:00 Agent 主动写 working context
agent.tool.call("core_memory_append", label="human",
    value="Familiar with Python; prefers simple deployment")
agent.tool.call("core_memory_append", label="project",
    value="Personal blog; framework: FastAPI")

# 周六 15:00 决策变更——主动 replace 而非新增
agent.tool.call("core_memory_replace", label="project",
    old="framework: FastAPI", new="framework: Flask")
# working context 里只剩 Flask，FastAPI 直接消失

# 周日 14:00 数据库决策变更
agent.tool.call("core_memory_replace", label="project",
    old="database: PostgreSQL", new="database: SQLite")
# project block 当前值：Personal blog; framework: Flask; database: SQLite

# 周日结束 Memory Pressure 触发 → 旧项目 page out 到 archival
agent.tool.call("archival_memory_insert",
    content="Project 2026-W19: blog (Flask, SQLite, Docker)")
```

读取路径（周日 10:00 学员问"最终用什么框架？" Agent 如何回答）：

Letta 的核心读取机制和 Mem0 完全不同——它**不在查询时才检索**，而是**让 working context 始终在 prompt 里**。Agent 每一轮 reasoning 看到的 prompt 都自动包含：

```
system 指令
+ persona block（Agent 身份设定）
+ human block（用户档案，例如："Familiar with Python; prefers simple deployment"）
+ project block（项目状态，例如："Personal blog; framework: Flask; database:
SQLite"）
+ recent FIFO messages（最近若干轮对话）
```

所以学员问"最终用什么框架"时：

```
# session 重启后，Letta 从 PostgreSQL 重新加载 working context
# Agent 收到学员问题，main context 自动注入 working context
# Agent 的 prompt 里已经能看到 "project: framework: Flask"

# Agent 直接 reasoning 后回答："你最终用的是 Flask，数据库换成 SQLite 了"
# 准确率 ~95%——working context 里没有 FastAPI 这条旧值

# 如果 working context 没装下需要的事实（被 page out 了），Agent 主动调：
agent.tool.call("archival_memory_search", query="framework decision")
# 召回的结果通过 function return 进入 Agent 下一轮 reasoning
```

周一 09:00 新项目跨项目复用：

```
# project block 已 page out，working context 重置为空 project
# human block 自动跟着 Agent 保留（用户档案与项目无关）
# Agent 看到 human block："Familiar with Python; prefers simple deployment"
# 直接基于偏好给推荐——但具体技术决策需要：

agent.tool.call("archival_memory_search", query="previous blog project")
# 召回 archival 里的 "Project 2026-W19: blog (Flask, SQLite, Docker)"
# Agent 综合 human 偏好 + 历史项目档案给出新建议
```

对四个挑战的表现：

挑战	表现	说明
① 写入策略	⚠️ Agent 主导	LLM 必须自己判"该 append 还是 replace"，漏调一次旧值就残留
② 冲突解决	✅ 精确覆盖	`core_memory_replace` 直接覆盖，working context 里只有最新值
③ 跨 session 召回	✅ 完整恢复	session 重启从 PostgreSQL 加载，working context 完整还原
④ 跨项目复用	⚠️ 半自动	human block 自动跟随 Agent，但项目经验需要 `archival_memory_search`

代价：context block 大小固定（典型 2-8KB），存满了必须 page out。所有写入都依赖 Agent 主动 tool call——工程上比 Mem0 的"无脑灌"复杂得多，但**可观测性**好——working context 在 Letta ADE 网页端实时可见。

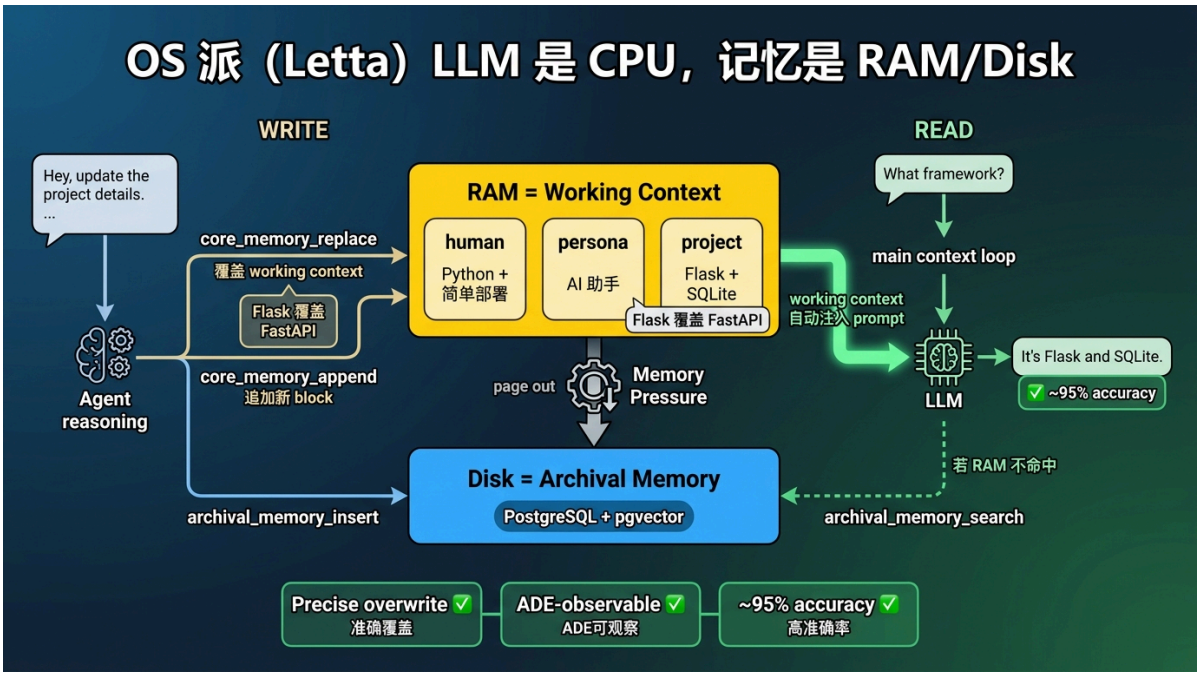

思路三：文档派 — markdown 文件就是真相源

机制：记忆的载体就是文件系统里的 markdown 文件。Agent 通过 `view` / `create` / `str_replace` 等文件操作工具读写笔记。操作员（人）也可以直接编辑同一份文件——人和 Agent 共享同一份真相。所有变更走 git，决策演化可 diff 可回滚。

写入路径（周末项目场景下的关键代码）：

```
# 周六 09:00 Agent 创建两个文件：用户档案 + 项目笔记
agent.tool.call("create", path="notes/user-zhang.md",
    content="# 用户档案\n- 语言：Python\n- 部署偏好：简单")
agent.tool.call("create", path="notes/blog-2026-w19.md",
    content="# 个人博客项目\n- 框架：FastAPI\n- 数据库：PostgreSQL")

# 周六 15:00 决策变更——str_replace 改文件，git 自动 commit
agent.tool.call("str_replace", path="notes/blog-2026-w19.md",
    old="框架：FastAPI", new="框架：Flask（部署考虑）")
# git history 完整保留 FastAPI → Flask 的演化

# 周日 14:00 数据库决策变更
agent.tool.call("str_replace", path="notes/blog-2026-w19.md",
    old="数据库：PostgreSQL", new="数据库：SQLite（轻量化）")
# 当前 notes/blog-2026-w19.md：
#   # 个人博客项目
#   - 框架：Flask（部署考虑）
#   - 数据库：SQLite（轻量化）
```

读取路径（周日 10:00 学员问"最终用什么框架？" Agent 如何回答）：

文档派的读取最直接——Agent 直接 view 文件，看到的就是最新真相：

```
# 学员问 "上次咱们最终用什么框架？数据库还用 PostgreSQL 吗？"
# Agent 主动选择读哪个文件

# 路径 A：精确读取（Agent 已知项目笔记位置）
agent.tool.call("view", path="notes/blog-2026-w19.md")
```

```
# 返回完整文件内容（当前状态，无矛盾）：
#   # 个人博客项目
#   - 框架：Flask（部署考虑）
#   - 数据库：SQLite（轻量化）
# Agent 直接回答："你最终用的是 Flask，数据库已经换成 SQLite 了"
# 准确率 ~100%——文件即真相

# 路径 B：模糊查询（笔记多了之后必备的 hybrid 检索）
gbrain query "最终用什么框架" --no-expand
# 触发 hybrid 检索（向量相似度 + BM25 关键词匹配 + RRF 融合）
# 召回 notes/blog-2026-w19.md 的相关片段
# Agent 综合召回内容回答

# 想看决策演化？git log 一行就行
git log -p notes/blog-2026-w19.md
# 显示 FastAPI → Flask、PostgreSQL → SQLite 的完整 diff history
```

周一 09:00 新项目跨项目复用：

```
# Agent 创建新项目笔记，显式 link 用户档案
agent.tool.call("create", path="notes/todo-2026-w20.md",
    content="""# Todo list 项目
- 用户档案：[见 user-zhang.md](user-zhang.md)
- 历史项目参考：[blog-2026-w19.md](blog-2026-w19.md)
- 技术栈：（基于偏好推荐：Flask + SQLite + 简单部署）""")
# 跨项目复用通过 markdown link 显式发生——可读、可追溯、可 git blame
```

对四个挑战的表现：

挑战	表现	说明
① 写入策略	⚠️ 显式	Agent 必须自己想清楚"写哪个文件、写什么内容"
② 冲突解决	✅ 文件覆盖	`str_replace` 直接改，git diff 保留完整演化
③ 跨 session 召回	✅ 文件持久	文件系统天然持久，`view` 即可，无需复杂查询
④ 跨项目复用	✅ markdown link	显式 link 引用，跨项目关系一目了然

代价：依赖 Agent（或操作员）显式维护文件——不像自动管家派"无脑灌入"那样省心。笔记数量大时检索效率是问题，所以 GBrain、Anthropic Memory Tool、Claude Code 都在 markdown 之上叠了向量索引 + hybrid 检索（§4 GBrain 章节会实操演示）。

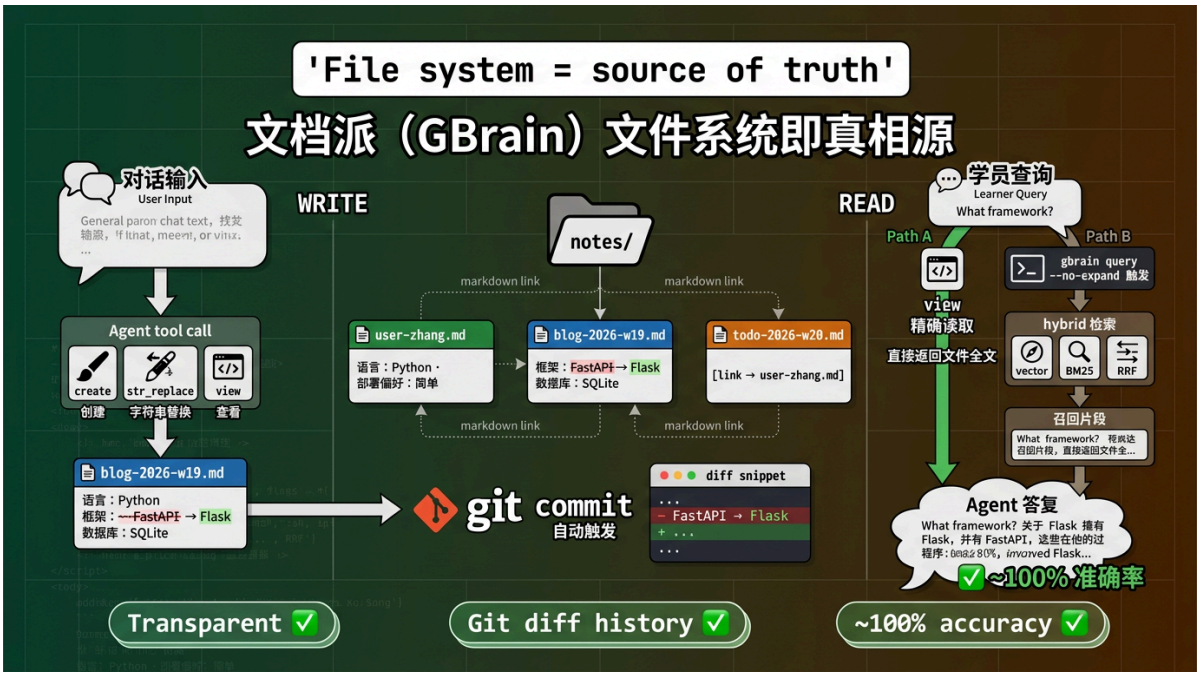

三派对四大挑战的表现汇总

把上面三个思路的表现并排放一起，**没有哪派"完胜"**——每派都在不同维度做了取舍：

挑战	自动管家派（Mem0）	OS 派（Letta）	文档派（GBrain）
① 写入策略	✅ 全自动（黑盒）	⚠️ Agent 主动 tool call	⚠️ 显式文件操作
② 冲突解决	⚠️ V3 ADD-only，矛盾并存（60-75%）	✅ `core_memory_replace` 精确覆盖（~95%）	✅ `str_replace` + git history（~100%）
③ 跨 session 召回	✅ 事实库持久	✅ PostgreSQL 加载	✅ 文件持久
④ 跨项目复用	✅ 同 user_id 自动	⚠️ human 自动 / project 半自动	✅ markdown link 显式
内部状态可见性	❌ 黑盒	✅ ADE 实时可见	✅ 直接看文件 / git diff

> 这张表是三派对比的核心——读到这里学员应该能形成一个朴素直觉：**自动管家派牺牲了可观测性换取写入便捷、OS 派牺牲了便捷性换取精确控制、文档派牺牲了自动化换取完全透明。**三种取舍各自适配不同场景。

三派对比表（设计哲学维度）

> 截至 2026-05-14 GitHub Stars 实测，下同。
>
> **术语速记**（表中首次出现）：CRUD = 增 / 改 / 删 / 读四类操作的合称；RAM / Disk = 内存 / 硬盘；FIFO queue = 先进先出队列；pgvector = PostgreSQL 的向量扩展；SaaS = 软件即服务（云端托管按用量付费）。

维度	自动管家派	OS 派	文档派
代表项目	**Mem0**（55.6k ⭐、$24M A 轮）	**Letta**(22.7k ⭐，前身 MemGPT)	**GBrain**(15.5k ⭐，2026-04-05 开源)
设计哲学	LLM 当后台管家，把对话提炼成结构化事实做 CRUD	LLM 是 CPU、记忆是 RAM/Disk，让 LLM 自己 page in/out	文件系统就是真相源，markdown 直接是记忆载体
学术血统	arXiv 2504.19413（Chhikara 等，2025-04）	arXiv 2310.08560（Berkeley Sky Computing Lab，2023-10）	Karpathy "PDFs/notes 是 source code, wiki 是 binary" 思想的工程化
写入方式	异步抽取，后台 LLM 自动判 ADD/UPDATE/DELETE/NOOP	Agent 主动调 function（`core_memory_replace`、`archival_memory_insert`）+ Memory Pressure 触发 flush	显式文件操作（`view`、`create`、`str_replace`、`insert`、`delete`、`rename`）
存储载体	密集自然语言事实条目（向量库 + SQLite 历史）	working context block + FIFO queue + archival/recall 数据库	markdown 文件 + 向量索引 + 可选知识图谱
执行位置	self-hosted 或 Mem0 Cloud（SaaS 双形态）	self-hosted（PostgreSQL + pgvector）或 Letta Cloud	client-side（操作发生在你自己的文件系统）
典型适用场景	客服 Agent、个性化推荐——不要求白盒、要快速接入	stateful agent runtime、长任务陪跑——要可观测、可手动调记忆	知识管理、个人 brain、跨工具复用——要可读、可 diff、可版本化

> 三派的根本差异在于"**让谁来掌握记忆的写入权**"：自动管家派交给后台 LLM、OS 派交给 Agent 自己、文档派交给操作员。这一个决策决定了后续可观测性、可控性、可移植性的全部走向。

同一句话三种处理（最直观的差异印证）

上面用周末项目演示了**整个时间线**上的差异。再用一句话演示**单次写入**的差异——把"**我叫 Alice Wang，是阿里巴巴 Python 工程师**"喂进三派代表项目，得到的内部存储完全不同：

流派	内部存储形态	控制粒度
自动管家派（Mem0）	后台 LLM 抽取并**翻译为英文 fact**：`"User's name is Alice Wang and she is a Python engineer at Alibaba"`	黑盒 / 自动
OS 派（Letta）	写入名为 `human` 的 working context block，agent 自己决定后续如何修改	半自动 / Agent 主导
文档派（GBrain）	**完整保留 markdown 原文** + embedding 索引（用户写啥就存啥）	白盒 / 操作员主导

> 完整对照（含载体形态、检索方式、可移植性）会在 §5a 收束时统一呈现。这里先建立直觉。

同流派其他项目速查

每派都不是只有一个代表项目。下表列出同流派的其他主流项目，便于学员选型时横向参考：

流派	代表项目	同流派其他项目（速查）
自动管家派	Mem0	LangMem（background mode，LangChain 出品）/ A-MEM（Zettelkasten 卡片盒笔记法风格的演化记忆，NeurIPS 2025）/ Zep（temporal-graph 即带时间维度的图谱形态，专做时序事实）
OS 派	Letta	MIRIX（六类记忆 + 多 Agent 分工 + 屏幕活动追踪）/ MemOS（textual + activation + parametric 三类记忆 OS）
文档派	GBrain	Anthropic Memory Tool（first-party API 化的文档派，2025-09）/ Anthropic Skills（按需加载的程序性记忆）/ Claude Code 的 CLAUDE.md hierarchy / Cursor Rules + Memories

> Zep 严格上是 temporal-graph 派（**单独的第四派**），但其工程形态最接近自动管家派的"后台抽取 + 主动维护事实库"，所以归在此处便于学员对照。Zep 反对全自动抽取、强调显式 schema 注入，是这条路线上的反潮流声音。

按场景的选型建议

业务场景	优先派别	推荐项目	理由
客服 Agent / 聊天助理需要个性化（用户偏好、历史话题）	自动管家派	Mem0	接入成本低、多用户隔离开箱即用、`add()` 一行喂入
长任务跨 session 陪跑（编程助手、研究助手）	OS 派	Letta	working context 实时可见、跨 session 持久化、可手动调
知识沉淀 / 已有 markdown 笔记复用 / 要求可读可 diff	文档派	GBrain	markdown 即记忆、知识图谱可视化、与 Obsidian / Cursor rules 思路一致

业务场景	优先派别	推荐项目	理由
不确定、想做 PoC	三派各跑一遍 demo 再选	Mem0（最快）→ Letta（中等）→ GBrain（中等）	部署难度递增，三派各跑一遍后对差异最有体感

一个常见误区：流派之间不是"哪个最强"

学员第一次接触这些项目，最容易陷入"排行榜思维"——把 Mem0、Letta、Zep 摆在一起问哪个 benchmark 分数高。这条路通常走不通：

- **三家根本不在同一条赛道上。**Mem0 优化"消费者级 chatbot 的开发体验"，Letta 优化"stateful agent runtime 的可观测性"，GBrain 优化"知识工作者自己持有的 brain repo"。把它们放在同一个 LOCOMO benchmark 上对比，类似于让 PostgreSQL、Redis、ElasticSearch 比"哪个最快"——问题本身就不成立。
- **Memory benchmark 的水分目前很大。**同一个 LOCOMO 评测，Mem0 自测 Zep 65.99 分，Zep 自测 75.14 分，Letta 用 grep 暴力检索拿到 74.0 分——三家数字相互矛盾。在 2026 年这一阶段，benchmark 不能作为选型主依据，**载体形态和写入方式更接近本质。**
- **三派可以并存于一个项目中。**一个稍复杂的 Agent 系统完全可以同时使用：Mem0 管用户偏好、Letta 跑长任务 runtime、GBrain 当团队知识库。**它们不是替代关系，是分工关系。**

流派图示

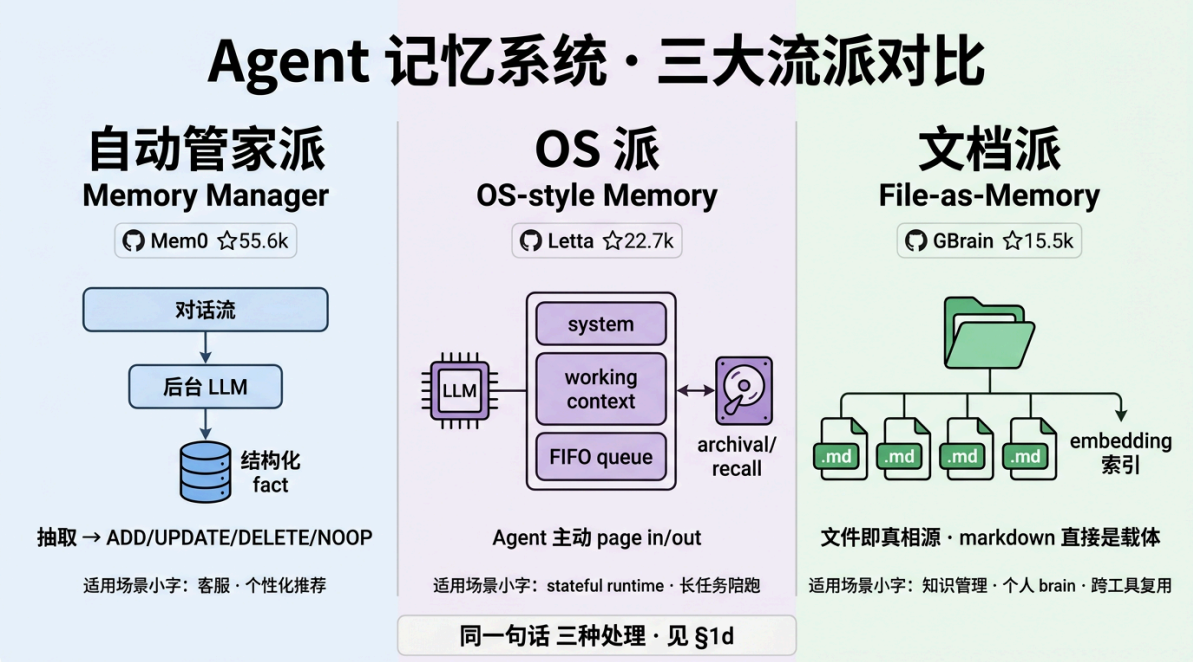

> 上图为三大流派的设计哲学速记图——同一条用户输入分别走入 Mem0 后台抽取链路、Letta working context 链路、GBrain markdown 文件链路。

---

§1e 顶流工具记忆系统归类

§1d 把当代 Agent 记忆系统按设计哲学收敛到三大流派——自动管家派 / OS 派 / 文档派。这一节把这张地图叠加到学员每天打交道的顶流工具上，解决一个具体问题：**你在用 Claude Code、OpenClaw、Cursor、Karpathy LLM Wiki、Anthropic Memory Tool 时，背后跑的是什么记忆系统、属于哪一派、为什么它们这么选。**

> 本节是速查表 + 推理路径，便于团队选型时"对标顶流"做出合理判断。

速查映射表

> 下表数字（stars / 发布时点）截至 2026-05-14 实测。

工具	记忆系统设计	流派归属	为什么这么选
Claude Code	`CLAUDE.md` 4 层作用域（Managed policy 组织级 / User 个人 / Project 团队 / Local 本机）+ Auto Memory（Claude 自己写的笔记）+ Memory Tool（API 形态）	**文档派**	用户拥有完全控制权 / 可 git 版本化 / 跨工具复用（Cursor 等也能读 markdown）
OpenClaw（早期）	`memory.md` + 混合检索（vector 0.7 + BM25 0.3）	**文档派 + 朴素 RAG**	起步阶段最低成本方案 / 与 markdown 生态零认知差
OpenClaw（2026-04-07 起的 `memory-wiki` 插件）	在 `memory.md` 之上叠 `memory-wiki` 插件（结构化 claim 即"主张/事实条目" + provenance 即"出处溯源元数据" + `wiki_lint` 校验工具）	**文档派**（结构化升级版）	解决朴素方案的"写入策略 / 冲突解决"两堵墙
OpenClaw 完整记忆栈	`MEMORY.md`（长期）+ `memory/YYYY-MM-DD.md`（每日工作记忆）+ `SOUL.md`（人格）+ `AGENTS.md`（规则）+ `HEARTBEAT.md`（定时任务）	**文档派**（多文件分层）	不同生命周期的内容用不同文件承载，符合"关注点分离"原则（separation of concerns）
Karpathy LLM Wiki（思想源头）	Obsidian 笔记库 + LLM 自动维护 wiki（每加新文档触发更新现有页 / 修订摘要 / 标矛盾 / 加交叉引用）	**文档派**（思想原型）	"PDFs 和 notes 是 source code，wiki 是 binary"——把记忆当编译产物
Cursor Rules + Memories	`.cursor/rules/*.mdc` 文件（mdc = Cursor 自定义的 markdown 变体，YAML frontmatter 元数据 + markdown 正文）+ Team / Project / User 三级作用域 + Memories 自动生成	**文档派**（带元数据）	mdc 的 frontmatter 可声明触发条件（globs / agentRequested 等），让规则按场景激活而非无差别加载
Anthropic Memory Tool	6 个原语命令（`view` / `create` / `str_replace` / `insert` / `delete` / `rename`）+ **client-side execution**（命令在你的应用进程里执行，Anthropic 服务端不存数据、文件存哪由你决定）	**文档派**（first-party API 化，即模型厂商官方提供的 API）	官方 API 化让任何开发者都能复用文档派模式，不用自己造轮子

工具	记忆系统设计	流派归属	为什么这么选
Anthropic Skills	`.skills/{name}/SKILL.md` + 按需加载（progressive disclosure，渐进披露——分三层：先读 metadata，命中后读 SKILL.md 主体，需要细节时再读 referenced files）	**文档派**（程序性记忆变体）	把"该怎么做某件事"做成可发现可加载的资源，是 Voyager（NVIDIA 2023 论文中的开放世界 Agent，提出"自动积累技能库"概念）skill library 思路的工业化版

一个共性：顶流工具不约而同选了文档派

把这些工具列在一起会发现一个反直觉的事实——**当代被广泛部署、用户量最大的 Agent 工具，绝大多数都是文档派。**

为什么自动管家派和 OS 派没有占据顶流位置？

视角	自动管家派为什么不太适合做顶流工具	OS 派为什么不太适合做顶流工具
用户控制权	后台 LLM 决定 ADD/UPDATE/DELETE，用户看不见、无法手动改	working context 由 Agent 主导，用户介入成本高
可移植性	数据藏在数据库里，换工具就丢	强绑定特定 runtime（Letta server / PostgreSQL）
可读性	抽取后的英文 fact 不一定符合用户表达习惯（Mem0 中→英翻译就是典型例子）	working context 是结构化字段，不是自然阅读形态
可调试性	97.8% junk 这种问题用户事后才能发现	调一个 working context block 比改一个 markdown 文件流程长

文档派恰好在这四点上都给到答案：**markdown 文件可见、可改、可 git、可被任何工具读取。**这是它能成为顶流默认选择的根本原因。

> 这不是说文档派"赢了"——下面 §2 / §3 会演示 Mem0 / Letta 在它们各自适合的场景里依然是更优解。**顶流工具选文档派 ≠ 你的项目也该选文档派。**选型仍然要回到 §1d 的三派对比表去判断"我要解决的问题更接近哪一派的强项"。

推理：怎么从"工具表象"反推"记忆流派"

学员遇到一个新的 Agent 工具，可以用以下三步快速判断它属于哪一派：

问题	答"是" → 倾向于...
1. 记忆是否以人类可读的文件形式落到磁盘上？	**文档派**
2. 是否有一个明确的"后台进程 / 异步任务"在我对话之外动作？	**自动管家派**
3. Agent 是否会在我面前显式调用 `memory_*` 之类的工具来读写记忆？	**OS 派**

> 同一个工具可能在不同维度命中不同流派——例如 OpenClaw 既有 markdown 文件（文档派）又有"Active Memory + Dreaming"机制（接近自动管家派的后台精炼）。**绝对纯粹的单一流派不多，但主要载体决定了归属。**

一张图看完顶流映射

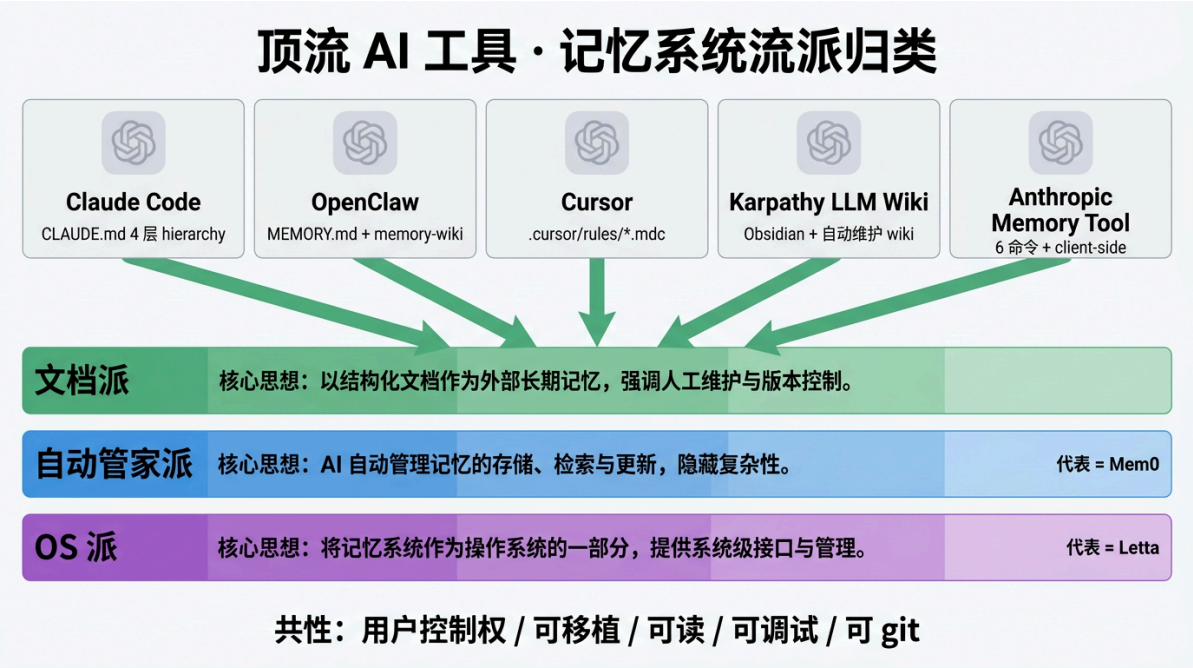

> 上图把 5 个常用工具（Claude Code / OpenClaw / Cursor / Karpathy LLM Wiki / Anthropic Memory Tool）映射到三派色带——文档派色带集中承接所有工具，自动管家派与 OS 派分别留出 Mem0 / Letta 作为代表项目供后续章节展开。

进入实操

§1 把背景认知建完——三派的全景图、与 RAG 的边界、顶流工具的归类——都已就位。从下一节（§2）开始，进入三派代表项目的逐个实操：

章节	流派	代表项目	演示重点
§2	自动管家派	Mem0	后台抽取 + 多用户隔离 + 检索分数
§3	OS 派	Letta	working context 实时演化 + 跨 session 记忆
§4	文档派	GBrain	markdown 即记忆 + hybrid 检索 + admin UI 知识图谱

每节都基于预先生成的真实数据集（Mem0 150 条 / Letta 80 turn / GBrain 225 笔记）演示，不使用 hello-world 级浅例子。

---

§5a 上集回顾：三派对照与下集预告

§1 把背景认知建完，§2 / §3 / §4 把 Mem0、Letta、GBrain 三个代表项目分别本地跑通。本节把上集的认知拼图收紧——三派如何处理同一句话、本集涉及到的核心认知洞察、以及下集 Part 3 工程化项目的承接。

同一句话三种处理（核心收束）

把"**我叫 Alice Wang，是阿里巴巴 Python 工程师**"这一句话喂入三派代表项目，得到的内部状态完全不同。下表把 §2c / §3 / §4c 的实测结果合并对照——这是上集最具体的"流派差异坐标"。

维度	自动管家派（Mem0）	OS 派（Letta）	文档派（GBrain）
载体形态	向量库里的 fact 条目（密集自然语言）	`human` working context block（结构化字段）	一个 markdown 文件
存储位置	默认 Qdrant 向量库（在 `/tmp/qdrant`）+ SQLite 历史变更库（在 `~/.mem0`）	PostgreSQL + pgvector（Recall Storage 存消息历史 + Archival Storage 存向量化事实）	`~/notes/people/alice-self-intro.md`
内部表示	英文 fact：`"User's name is Alice Wang and she is a Python engineer at Alibaba"`	写入 `human` block 的 value 字段，由 agent 用 `core_memory_replace` 自行决定后续修改	原句逐字保留：`我叫 Alice Wang，是阿里巴巴 Python 工程师`
处理粒度	信息原子化——一句多维度会被拆成多条 fact，强相关属性合并打包	整段文本写入 block，由 agent 决定何时合并/覆盖	一个完整 chunk（含 frontmatter + 正文 + 链接）
是否做语言转换	✅ 自动翻译为英文（V3 ADDITIVE_EXTRACTION_PROMPT 默认行为，`use_input_language=False`）	❌ 保留原文，但 agent 后续可改写	❌ 完整保留
写入触发	异步——后台 LLM 抽取 → ADD（V3 不再自动 UPDATE/DELETE）	Agent 显式调 `core_memory_replace` 或 Memory Pressure 触发	显式 `gbrain import` 或 `gbrain sync --watch` 文件监听
同条事实演化	旧 fact 不自动删除，business 侧负责清理	working context 由 agent 主动 replace 覆盖	markdown 直接编辑或新增笔记
可移植性	切工具就丢（数据藏在数据库结构里）	强绑定 Letta runtime + PostgreSQL	一个目录推 git 即走
可读性	需 SDK 读，且看到的是英文 fact	需 Letta SDK / ADE 读	任何 markdown 编辑器打开就是

维度	自动管家派（Mem0）	OS 派（Letta）	文档派（GBrain）
检索路径	`m.search(query, filters={"user_id": uid}, version="v2")` ——默认走 Qdrant 向量相似度，按 `filters` 过滤 scope	working context 永远 in-context，archival / recall 通过 `archival_memory_search` / `conversation_search` tool 调用查	`gbrain query "..." --no-expand` ——向量 + BM25 + RRF 融合

> 同一条信息，三派给出三种完全不同的内部状态。这不是"哪种最好"的问题，是设计哲学的本质分歧——**让谁来掌握记忆的写入权**：自动管家派交给后台 LLM、OS 派交给 Agent 自己、文档派交给操作员。

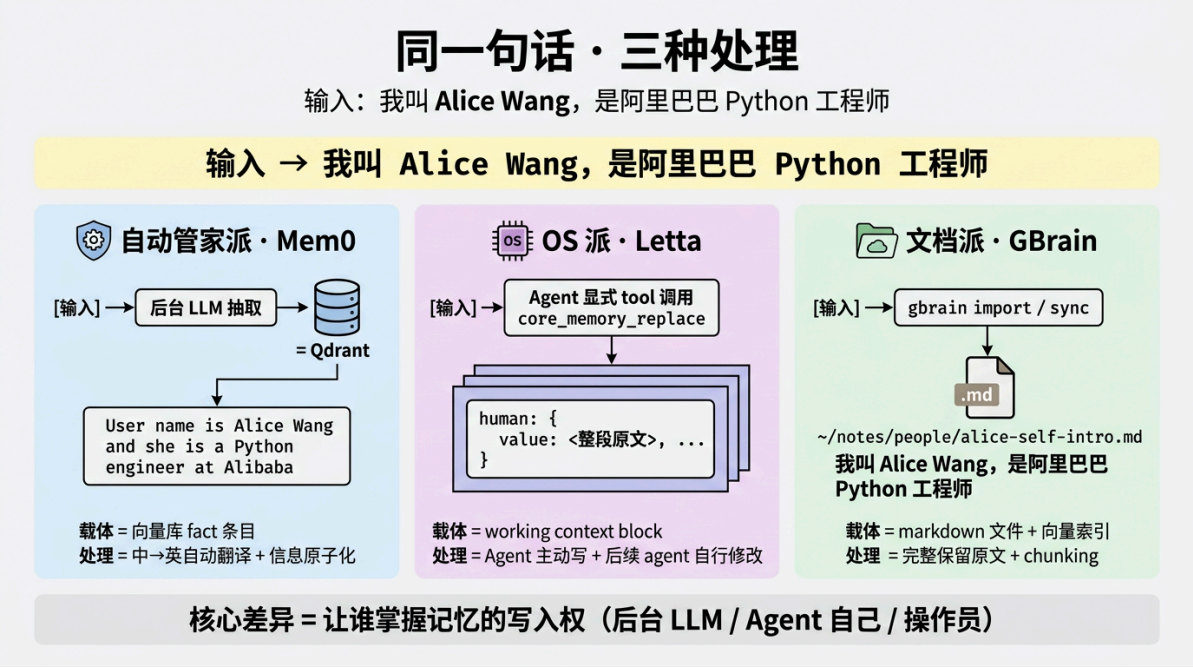

本集核心认知洞察（5 条）

#	洞察	实证来源
1	**Agent 记忆 ≠ Context Engineering ≠ RAG**——三者是协作不是替代。Context Engineering 管 prompt 长度、RAG 查静态文档、Agent 记忆是持久 / 自我演化 / 跨会话的外部状态层	§1b 三者关系表 + Anthropic context rot 官方背书
2	**三派一图记住**：自动管家派让后台 LLM 偷偷整理（Mem0）/ OS 派让 LLM 自己 page in/out（Letta）/ 文档派 markdown 即真相（GBrain）。三家不在同一赛道上，benchmark 互怼说明 LOCOMO 这类对比不可作选型主依据	§1d 三派对比表 + LOCOMO 三方互怼数据
3	**顶流工具不约而同选了文档派**：Claude Code、OpenClaw、Cursor、Karpathy LLM Wiki、Anthropic Memory Tool 全部以 markdown 文件作为记忆真相源——共性是用户控制权 / 可移植 / 可读 / 可调试 / 可 git。这不等于你的项目也该选文档派——选型仍要回到 §1d	§1e 顶流映射表
4	**载体形态决定能做什么**：同一句话三种处理对照清楚展示了"中→英自动翻译 vs 写入 working context vs 保留 markdown 原文"在可移植性 / 可读性 / 可调试性上的不同代价。技术上无最优解，trade-off 不同	§2c / §3 / §4c 实测 + 本节对照表

#	洞察	实证来源
5	**默认配置 ≠ 生产配置**：Mem0 默认 prompt 在生产上跑 32 天会 97.8% junk（issue #4573 实测），GBrain query expansion 默认开会卡 30s+，Letta 默认 letta-free key 失效。任何记忆系统在上生产前都要看默认值、看默认 prompt、看默认 model。Selective Forgetting 是 2026 全行业未解难题，所有现代系统在"该忘的没忘"任务上准确率最高 7%	§1c 局限 4 + §2 / §3 / §4 各项目 watch-out

回到开场的问题

§1a 的开场提了一个问题——Claude Code、OpenClaw、Cursor 之所以做一周项目还能记得需求、升级版本后还能跑你之前的工作流，**关键不在于 LLM 多强，而在于它们各自配了一套显式的 Agent 记忆系统。**

到这一节，这个判断有了具体的拆解：

顶流工具	流派归属	你现在能说出
Claude Code	文档派	`CLAUDE.md` 4 个作用域（Managed policy / User / Project / Local）+ Auto Memory，载体是 markdown 文件
OpenClaw	文档派（多文件分层）	`MEMORY.md` 长期 + `memory/YYYY-MM-DD.md` 每日 + `SOUL.md` 人格，2026.4.7 起还有 `memory-wiki` 结构化插件
Cursor	文档派（带元数据）	`.cursor/rules/*.mdc` + Team / Project / User 三级作用域
Karpathy LLM Wiki	文档派（思想原型）	Obsidian 笔记库 + LLM 维护 wiki，"PDFs 是 source code, wiki 是 binary"
Anthropic Memory Tool	文档派（first-party API）	6 个原语命令，client-side execution，由你的应用决定文件存哪

判断它们用什么记忆系统——上集要解决的就是这件事。

三派可以并存

需要再次明确：上集学的三派**不是替代关系，是分工关系。**一个稍复杂的 Agent 系统完全可以同时使用：

- **Mem0** 管个性化用户偏好（客服 Agent / 助理 Agent 的记得"用户喜欢什么"）
- **Letta** 跑长任务陪跑（编程助手 / 研究助手的"working context 自动 page in/out"）
- **GBrain** 当团队知识库（已有的 Obsidian / Cursor rules / CLAUDE.md 沉淀复用）

加上 RAG 查产品文档、Context Engineering 控制 prompt 长度，构成成熟 Agent 系统的完整记忆栈。

下集预告：Part 3 工程化项目

下集（Part 3）会基于上集学的三派认知，再向前走一步——**一个可在三种记忆后端之间切换的 web 对话产品**：

- 技术栈：LangChain 1.x + LangGraph `create_agent`（学员日常工具，零认知成本）
- 后端可切换：现场演示同一对话切到 Mem0 / Letta / GBrain，看到记忆呈现的形态差异（即上面"同一句话三种处理"的可视化版）
- GitHub 完整源码公开：学员可直接 fork 接入自己的项目
- 引流方向：完整工程化能力（生产部署 / 评估方法论 / 监控告警 / Selective Forgetting 工程化对策 / benchmark 水分识别）在付费课展开

下集开课时间：预计 **2-3 周内开课**（具体日期等团队 web 工程化项目最后联调完毕公布）。**想第一时间收到下集开课通知 + 拿到 GitHub 仓库地址**，请扫码加入九天智课 Agent 记忆系统专题群——下集开课首日群内首发，付费课早鸟价同步开放。

本集做了什么 / 没做什么

上集做了	上集没做（在下集 Part 3 / 付费课展开）
三派对比表 + 顶流工具流派归类	工程化生产部署（Docker / Kubernetes / 监控告警）
两个代表项目本地跑通 + 核心功能演示（Mem0 + GBrain）+ Letta 设计原理与速查	可切换三后端的 web 产品（下集核心）+ Letta docker compose + ADE 实操（本课件后续版本补齐 ADE 截图）
同一句话三种处理对照	评估方法论（LongMemEval / LoCoMo / BEAM 三大 benchmark）
真实生产坑示例（Mem0 97.8% junk 等架构性坑）	benchmark 水分识别 + 厂商互怼细节
选型决策维度（载体形态 / 写入方式）	Selective Forgetting 工程化对策
三派各自的"更多功能速查表"（§2d / §3d / §4d）	各项目内部数据结构 / 检索算法实现细节

> 上集学完后，学员手上有：一份三派对比表、三个本地跑通的代表项目、一份顶流工具映射、一组真实演示数据集（150 条对话 / 80 turn 跨 5 session / 225 笔记）。可以基于自己的业务场景做出"该选哪派"的初步判断，也可以把演示数据集复用到自己环境继续验证。

Sources（上集主要事实来源）

- Anthropic Effective Context Engineering for AI Agents
- Mem0 论文 arXiv 2504.19413
- MemGPT 论文 arXiv 2310.08560
- mem0/issues/4573 — 32 天 10134 条记忆 97.8% junk 审计
- Generative Agents 论文 arXiv 2304.03442（三因子检索公式）
- Karpathy LLM Wiki Gist
- OpenClaw Memory Wiki Docs

- Claude Code Memory Documentation
- Cursor Rules Documentation
- Phase 2 实测报告